Parcial 1 — Teoría de Aprendizaje de Máquina

Métodos kernel, espacios de características y formulación matricial

Resolución paso a paso, con dimensiones y apoyo visual

Ever Hernandez
Juan David Villota

Índice

Convenciones, notación y símbolos **2**

1. Regresión en espacios de características **3**

Modelo y notación . . . 3

Propiedades de cálculo matricial (P1)–(P6) . . . 3

1.1. Mínimos cuadrados . . . 5

1.2. Mínimos cuadrados regularizados . . . 7

1.3. Máxima verosimilitud . . . 9

1.4. Máximo a posteriori (MAP) . . . 10

1.5. Implementación y análisis . . . 11

Síntesis del Problema 1 . . . 13

2. Espacios RKHS, embeddings de media y discrepancia entre distribuciones **14**

Herramientas: kernel, RKHS y propiedades (K1)–(K6) . . . 14

2.1. Embedding de media . . . 15

2.2. Pertenencia y significado geométrico . . . 17

2.3. Discrepancia máxima de medias (MMD): de la definición a la forma matricial . . . 18

2.4. Implementación con MNIST y Fashion-MNIST . . . 20

3. Índice de correlación de Pearson: espacio original y RKHS **21**

Herramientas: centrado y trazas . . . 21

3.1. Coeficiente de Pearson muestral en forma matricial . . . 22

3.2. Alineamiento centrado en RKHS . . . 23

3.3. Caso lineal con datos escalares: verificación de coherencia . . . 25

3.4. Verificación numérica . . . 26

Convenciones, notación y símbolos

Antes de resolver conviene fijar el terreno. Tres convenciones valen para todo el documento: (i) los vectores son *columnas* salvo que se indique lo contrario, de modo que $a^\top b$ es un escalar; (ii) cada objeto lleva su dimensión entre paréntesis la primera vez que aparece; y (iii) las propiedades se numeran y se citan por su etiqueta, nunca se reexplican.

Cuadro 1: Símbolos usados a lo largo del documento.

Símbolo	Dimensión	Qué es
N	entero	número de observaciones
P	entero	dimensión de cada entrada original
Q	entero	dimensión del espacio de características
x_n	$P \times 1$	entrada n-ésima, vector columna
t_n	escalar	respuesta n-ésima
$\phi : \mathbb{R}^P \to \mathbb{R}^Q$	mapa	transformación de características
$\phi(x_n)$	$Q \times 1$	entrada transformada, vector columna
$\phi(x_n)^\top$	$1 \times Q$	fila n-ésima de Φ
Φ	$N \times Q$	matriz de diseño (una fila por observación)
w	$Q \times 1$	pesos del modelo, lo que se estima
η_n, η	escalar, $N \times 1$	ruido, ruido apilado
t	$N \times 1$	respuestas apiladas
$\Phi^\top \Phi$	$Q \times Q$	Gram de las características
$\Phi^\top t$	$Q \times 1$	proyección de t sobre las columnas de Φ
I_Q	$Q \times Q$	matriz identidad
$r = t - \Phi w$	$N \times 1$	residuo
H_Φ	$N \times N$	matriz sombrero (proyección)
λ	escalar > 0	coeficiente de regularización
σ_η^2, σ_w^2	escalares > 0	varianza del ruido / varianza del prior
x, y	$N \times 1$	observaciones emparejadas (Problema 3)
H	$N \times N$	matriz de centrado $I_N - \frac{1}{N}\mathbf{1}_N\mathbf{1}_N^\top$
k	—	kernel, función de dos entradas
$\mathcal{H}_k$	espacio	RKHS asociado al kernel k
μ_k	función en $\mathcal{H}_k$	embedding de media de una distribución
K_{XX}	$n \times n$	Gram de la muestra X
$K_{X,c}$	$N \times N$	Gram centrada, HK_XH

Los objetos principales, escritos de forma explícita. Ver las entradas ayuda más que memorizar dimensiones:

$$x_n = \begin{bmatrix} x_{n,1} \\ \vdots \\ x_{n,P} \end{bmatrix}, \qquad \phi(x_n) = \begin{bmatrix} \phi_1(x_n) \\ \vdots \\ \phi_Q(x_n) \end{bmatrix}, \qquad w = \begin{bmatrix} w_1 \\ \vdots \\ w_Q \end{bmatrix}, \qquad t = \begin{bmatrix} t_1 \\ \vdots \\ t_N \end{bmatrix}, \tag{1}$$

$$\Phi = \begin{bmatrix} — \ \phi(x_1)^\top \ — \\ \vdots \\ — \ \phi(x_N)^\top \ — \end{bmatrix} \in \mathbb{R}^{N \times Q}. \tag{2}$$

Así se ve por qué Φ es $N \times Q$: una fila por observación y una columna por característica. El producto Φw combina linealmente las columnas de Φ con pesos $w_1, \ldots, w_Q$.

Detalle que suele confundir. Tres confusiones frecuentes. **(1) Q no es el mismo Q en todo el documento:** en el Problema 1 es la dimensión del espacio de características; en el Problema 3, P y Q son las dimensiones de x e y. **(2) Hay tres "H":** H es la matriz de centrado del Problema 3, H_Φ es la matriz sombrero del Problema 1 y $\mathcal{H}_k$ es el *espacio* RKHS del Problema 2. **(3) Función contra número:** $k(x,\cdot)$ y μ_k son *funciones*; $k(x,u)$ y $\mu_k(u)$ son *números*. Y $\mathbf{1}_n$ es el vector de unos, nunca el número 1.

1. Regresión en espacios de características

El Problema 1 estudia un mismo modelo desde cuatro perspectivas: mínimos cuadrados (1.1), mínimos cuadrados regularizados (1.2), máxima verosimilitud (1.3) y máximo a posteriori (1.4). Las tres derivaciones comparten el álgebra de la forma cuadrática asociada al modelo y la cuarta reutiliza el problema de optimización de la segunda. La verificación numérica cierra el problema en 1.5.

Modelo y notación

Qué se modela. Se dispone de datos i.i.d. $\{(x_n, t_n)\}_{n=1}^N$ con $x_n \in \mathbb{R}^P$ y $t_n \in \mathbb{R}$. Primero se transforma la entrada con un mapa explícito $\phi : \mathbb{R}^P \to \mathbb{R}^Q$ y *después* se hace regresión lineal sobre $\phi(x)$:

$$t_n = \phi(x_n)^\top w + \eta_n, \qquad w \in \mathbb{R}^Q, \qquad \eta_n \overset{\text{i.i.d.}}{\sim} \mathcal{N}(0, \sigma_\eta^2). \tag{3}$$

Cada símbolo tiene un papel preciso: x_n es la entrada, $\phi(x_n)$ su imagen en el espacio de características, w los pesos que se estiman, η_n el ruido y t_n la respuesta observada.

Variables clave. $x_n \in \mathbb{R}^P$ (P es la dimensión original), $\phi(x_n) \in \mathbb{R}^Q$ (Q es la dimensión de características, puede ser mayor que P), $w \in \mathbb{R}^Q$ (las Q incógnitas), η_n (ruido $\mathcal{N}(0, \sigma_\eta^2)$), t_n (respuesta). No confundir P (original) con Q (características) ni con N (número de observaciones).

Por qué "lineal en características" no significa lineal en los datos. Si $\phi(x) = (x, x^2)$ entonces $w^\top \phi(x) = w_1 x + w_2 x^2$: el modelo es cuadrático en x pero lineal en $\phi(x)$. La linealidad se pide en el espacio de características, no en el original.

Del modelo por observación al modelo matricial. Apilar las N ecuaciones permite usar álgebra matricial de una vez. La n-ésima componente de Φw es $(\Phi w)_n = \phi(x_n)^\top w$, porque es el producto de la fila n de Φ por w. Por tanto (3) se cumple para todo n si y solo si

$$\boxed{t = \Phi w + \eta.} \tag{4}$$

Dimensiones: $\Phi \in \mathbb{R}^{N\times Q}$, $w \in \mathbb{R}^{Q\times 1} \Rightarrow \Phi w \in \mathbb{R}^{N\times 1}$; con $\eta \in \mathbb{R}^{N\times 1}$, $\Phi w + \eta \in \mathbb{R}^{N\times 1} = t$.

Tabla de dimensiones. Con tantas matrices en juego, conviene tener la referencia a mano.

Propiedades de cálculo matricial usadas (P1)–(P6)

Se enuncian una sola vez, con su justificación, y en el resto del documento se citan por su etiqueta. Estas seis propiedades son toda la caja de herramientas del Problema 1.

Cuadro 2: Objetos del modelo, tipo y dimensiones.

Símbolo	Dimensión	Tipo	Qué es
x_n	$P \times 1$	vector columna	entrada n-ésima
t_n	escalar	número	respuesta n-ésima
$\phi(x_n)$	$Q \times 1$	vector columna	entrada transformada
$\phi(x_n)^\top$	$1 \times Q$	vector fila	n-ésima fila de Φ
w	$Q \times 1$	vector columna	pesos del modelo
η_n	escalar	número	ruido de la observación n
Φ	$N \times Q$	matriz	matriz de diseño
t, η	$N \times 1$	vectores columna	respuestas y ruidos apilados
$\Phi^\top$	$Q \times N$	matriz	transpuesta de Φ
$\Phi^\top\Phi$	$Q \times Q$	matriz	Gram de las características
$\Phi^\top t$	$Q \times 1$	vector columna	proyección de t
I_Q	$Q \times Q$	matriz	identidad
$r = t - \Phi w$	$N \times 1$	vector columna	residuo
H_Φ	$N \times N$	matriz	matriz sombrero

1. **(P1) Transposición.** $(AB)^\top = B^\top A^\top$, $(A^\top)^\top = A$, y es lineal: $(A \pm B)^\top = A^\top \pm B^\top$. *Para qué:* cada vez que se mueven matrices de un lado a otro de una igualdad el orden de los factores se invierte.

2. **(P2) El producto escalar es simétrico.** Si $a, b \in \mathbb{R}^k$, entonces $a^\top b = b^\top a = \sum_{i=1}^k a_i b_i \in \mathbb{R}$. En particular, al ser un escalar, $(a^\top b)^\top = a^\top b$. *Para qué:* dos expresiones que solo difieren en el orden de sus factores escalares son el mismo número.

3. **(P3) Derivada de una forma lineal.** Si $b \in \mathbb{R}^Q$ y $f(w) = b^\top w$, entonces $\nabla_w f = b$. *Justificación:* $b^\top w = \sum_{k=1}^Q b_k w_k$, luego $\partial f / \partial w_k = b_k$ y apilando las Q componentes, $\nabla_w f = b$.

4. **(P4) Derivada de una forma cuadrática simétrica.** Si $A = A^\top \in \mathbb{R}^{Q \times Q}$ y $f(w) = w^\top A w$, entonces $\nabla_w f = 2Aw$. *Justificación:* $w^\top A w = \sum_{i,j} A_{ij} w_i w_j$. Al derivar respecto de w_k solo sobreviven los términos con $i = k$ o $j = k$:

$$\frac{\partial}{\partial w_k}(w^\top A w) = \sum_j A_{kj} w_j + \sum_i A_{ik} w_i = (Aw)_k + (A^\top w)_k = 2(Aw)_k, \tag{5}$$

   donde en el último paso se usó $A^\top = A$. Apilando las Q componentes, $\nabla_w(w^\top A w) = 2Aw$.

5. **(P5) Hessiana de una forma cuadrática.** Si $f(w) = w^\top A w$ con A simétrica, entonces $\nabla_w^2 f = 2A$. *Justificación:* derivando (P4) componente a componente, $\partial(2Aw)_i / \partial w_j = 2A_{ij}$ (la matriz A no depende de w). *Para qué:* la hessiana dice si el punto crítico es un mínimo (2.2).

6. **(P6) Gradiente del residuo.** Con $r(w) = t - \Phi w$, $t \in \mathbb{R}^N$, $\Phi \in \mathbb{R}^{N \times Q}$, $w \in \mathbb{R}^Q$:

$$\boxed{\nabla_w \|t - \Phi w\|_2^2 = -2\,\Phi^\top (t - \Phi w).} \tag{6}$$

   Justificación: $\|t - \Phi w\|^2 = \sum_{n=1}^N r_n^2$ con $r_n = t_n - \phi(x_n)^\top w$. Por la regla de la cadena,

$$\frac{\partial}{\partial w_k}(r_n^2) = 2 r_n \frac{\partial r_n}{\partial w_k} = 2 r_n(-\phi_k(x_n)), \qquad \text{pues} \qquad \frac{\partial}{\partial w_k}\Big(t_n - \sum_j \phi_j(x_n) w_j\Big) = -\phi_k(x_n). \tag{7}$$

Sumando sobre n: $\partial\|t-\Phi w\|^2/\partial w_k = -2\sum_n r_n\phi_k(x_n) = -2(\Phi^\top r)_k$. Apilando las Q componentes se obtiene el resultado. *Para qué:* es el gradiente directo de la función objetivo de mínimos cuadrados, con el que las ecuaciones normales salen casi de inmediato.

1.1. Mínimos cuadrados

Idea. Elegir w para que la predicción Φw quede lo más cerca posible de t, midiendo la distancia con la norma euclídea al cuadrado (diferenciable, convexa y sensible a los errores grandes).

Variables clave. La incógnita es $w \in \mathbb{R}^Q$. El dato es $t \in \mathbb{R}^N$. El objeto que se ajusta es $\Phi w \in \mathbb{R}^N$, la combinación lineal de las columnas de Φ. La cantidad que se mide es el residuo $r = t - \Phi w \in \mathbb{R}^N$.

Función objetivo.

$$\boxed{J(w) = \|t-\Phi w\|_2^2 = (t-\Phi w)^\top (t-\Phi w).} \tag{8}$$

Dimensiones: $t \in \mathbb{R}^{N\times 1}$, $\Phi \in \mathbb{R}^{N\times Q}$, $w \in \mathbb{R}^{Q\times 1} \Rightarrow r = t-\Phi w \in \mathbb{R}^{N\times 1} \Rightarrow J(w) = r^\top r \in \mathbb{R}$ (escalar).

Expansión completa de la forma cuadrática. Por (P1), $(t-\Phi w)^\top = t^\top - (\Phi w)^\top = t^\top - w^\top\Phi^\top$, porque $(\Phi w)^\top = w^\top\Phi^\top$. Multiplicando los dos factores:

$$\begin{aligned} J(w) &= (t^\top - w^\top\Phi^\top)(t-\Phi w) \\ &= t^\top t \underbrace{- t^\top\Phi w}_{\text{(I)}} \underbrace{- w^\top\Phi^\top t}_{\text{(II)}} + \underbrace{w^\top\Phi^\top\Phi w}_{\text{(III)}}. \end{aligned} \tag{9}$$

Cada término es un escalar, con estas dimensiones:

$$t^\top t \in \mathbb{R}, \qquad (1\times N)(N\times 1), \tag{10}$$

$$\text{(I) } t^\top\Phi w \in \mathbb{R}, \qquad (1\times N)(N\times Q)(Q\times 1), \tag{11}$$

$$\text{(II) } w^\top\Phi^\top t \in \mathbb{R}, \qquad (1\times Q)(Q\times N)(N\times 1), \tag{12}$$

$$\text{(III) } w^\top\Phi^\top\Phi w \in \mathbb{R}, \qquad (1\times Q)(Q\times Q)(Q\times 1). \tag{13}$$

Por (P2), un escalar es igual a su transpuesta, y con (P1) dos veces,

$$t^\top\Phi w = (t^\top\Phi w)^\top = w^\top\Phi^\top(t^\top)^\top = w^\top\Phi^\top t, \tag{14}$$

de modo que (I) y (II) son el *mismo número* y se juntan en $-2w^\top\Phi^\top t$. Por tanto

$$\boxed{J(w) = t^\top t - 2\,w^\top\Phi^\top t + w^\top\Phi^\top\Phi w.} \tag{15}$$

Condición de optimalidad. J es cuadrática con matriz $\Phi^\top\Phi$ semidefinida positiva (se demuestra más abajo en este mismo punto), luego convexa: un punto con gradiente nulo es el mínimo global. Se deriva término a término; el primero es constante en w,

$$\nabla_w(t^\top t) = 0; \tag{16}$$

el segundo es escalar, así que se transpone (P2) y se aplica (P3):

$$-2\,w^\top\Phi^\top t = -2\,(w^\top\Phi^\top t)^\top = -2\,t^\top\Phi w = -2\,(\Phi^\top t)^\top w \implies \nabla_w(-2\,w^\top\Phi^\top t) = -2\,\Phi^\top t; \tag{17}$$

y el tercero, con $A = \Phi^\top\Phi$ simétrica por (P1) ($A^\top = \Phi^\top(\Phi^\top)^\top = \Phi^\top\Phi = A$), se deriva con (P4):

$$\nabla_w(w^\top\Phi^\top\Phi w) = 2\,\Phi^\top\Phi w. \tag{18}$$

Sumando los tres términos,

$$\nabla_w J(w) = -2\,\Phi^\top t + 2\,\Phi^\top\Phi w = 2(\Phi^\top\Phi w - \Phi^\top t). \tag{19}$$

Imponer $\nabla_w J = 0$ da las **ecuaciones normales**

$$\boxed{\Phi^\top\Phi\, w = \Phi^\top t.} \tag{20}$$

Dimensiones: $\Phi^\top\Phi \in \mathbb{R}^{Q\times Q}$, $w \in \mathbb{R}^{Q\times 1}$, $\Phi^\top t \in \mathbb{R}^{Q\times 1}$: sistema de Q ecuaciones con Q incógnitas.

Solución (si $\Phi^\top\Phi$ es invertible). Multiplicando (20) por la izquierda por $(\Phi^\top\Phi)^{-1}$:

$$\boxed{\hat{w}_{\mathrm{LS}} = (\Phi^\top\Phi)^{-1}\Phi^\top t.} \tag{21}$$

Comprobación: $\Phi^\top\Phi\,\hat{w}_{\mathrm{LS}} = \Phi^\top\Phi(\Phi^\top\Phi)^{-1}\Phi^\top t = \Phi^\top t$. ✓

Valores ajustados y matriz sombrero. Sustituyendo la solución en la predicción, todo el efecto del modelo se concentra en una sola matriz que actúa sobre t:

$$\hat{t} = \Phi\hat{w}_{\mathrm{LS}} = \underbrace{\Phi(\Phi^\top\Phi)^{-1}\Phi^\top}_{H_\Phi} t = H_\Phi t, \qquad H_\Phi = \Phi(\Phi^\top\Phi)^{-1}\Phi^\top \in \mathbb{R}^{N\times N}. \tag{22}$$

Dimensiones: $\Phi \in \mathbb{R}^{N\times Q}$, $(\Phi^\top\Phi)^{-1} \in \mathbb{R}^{Q\times Q}$, $\Phi^\top \in \mathbb{R}^{Q\times N} \Rightarrow H_\Phi \in \mathbb{R}^{N\times N}$; así $\hat{t} \in \mathbb{R}^N$ coincide con t. Se le llama *sombrero* porque "le pone el sombrero" a t: $\hat{t} = H_\Phi t$ es la proyección de t sobre el espacio de las predicciones posibles.

Existencia de la solución. *Antes de confiar en* (21) *hay que saber que el sistema nunca es incompatible.* Las ecuaciones normales siempre tienen solución. La razón es que el segundo miembro cae en la imagen de la matriz: $b = \Phi^\top t$ es $\Phi^\top$ aplicada a t, luego $b \in \mathrm{col}(\Phi^\top)$; y $\mathrm{col}(\Phi^\top\Phi) = \mathrm{col}(\Phi^\top)$, lo que se prueba con las dos inclusiones:

- ($\subseteq$) Todo $\Phi^\top\Phi z = \Phi^\top(\Phi z)$ es $\Phi^\top$ aplicada a un vector, luego está en $\mathrm{col}(\Phi^\top)$.
- ($\supseteq$) Sea $y = \Phi^\top z$ y descompóngase $z = z_1 + z_2$ con $z_1 \in \mathrm{col}(\Phi)$ y $z_2 \perp \mathrm{col}(\Phi)$. Como $z_2 \in \mathrm{nul}(\Phi^\top)$ se tiene $\Phi^\top z_2 = 0$ y $y = \Phi^\top z_1$; y $z_1 = \Phi u$ para algún u, de donde $y = \Phi^\top\Phi u \in \mathrm{col}(\Phi^\top\Phi)$.

Los dos subespacios coinciden, luego $b \in \mathrm{col}(\Phi^\top\Phi)$ y el sistema es consistente (Rouché–Capelli). Por convexidad, toda solución es minimizador global.

Unicidad. La curvatura del problema es la hessiana $\nabla_w^2 J = 2\,\Phi^\top\Phi$ (P5). Para todo $z \in \mathbb{R}^Q$,

$$z^\top(\Phi^\top\Phi)z = (\Phi z)^\top(\Phi z) = \|\Phi z\|^2 \geq 0, \tag{23}$$

usando $z^\top\Phi^\top = (\Phi z)^\top$. Luego $\Phi^\top\Phi$ es semidefinida positiva y J es convexa: todo mínimo local es global. La solución es *única* cuando la hessiana es definida positiva, es decir

$$\|\Phi z\|^2 > 0 \;\; \forall z \neq 0 \iff \mathrm{nul}(\Phi) = \{0\} \iff \mathrm{rango}(\Phi) = Q \iff \Phi^\top\Phi \text{ invertible}. \tag{24}$$

Por qué la última equivalencia: si $\Phi^\top \Phi x = 0$, multiplicando a la izquierda por $x^\top$ queda $\|\Phi x\|^2 = x^\top \Phi^\top \Phi x = 0$, luego $\Phi x = 0$; recíprocamente $\Phi x = 0 \Rightarrow \Phi^\top \Phi x = 0$. Así $\text{nul}(\Phi^\top \Phi) = \text{nul}(\Phi)$ y, siendo ambas matrices de tamaño $Q \times Q$, sus rangos coinciden. En particular $\text{rango}(\Phi) = Q$ exige $N \geq Q$.

Resultado. La solución existe siempre. Es única $\iff$ $\text{rango}(\Phi) = Q$ $\iff$ las Q columnas de Φ son linealmente independientes (condición necesaria: $N \geq Q$). Si $\text{rango}(\Phi) < Q$ hay infinitos minimizadores —si w_0 es uno y $v \in \text{nul}(\Phi)$ con $v \neq 0$, entonces $w_0 + v$ también lo es— y la solución de *mínima norma* es $\hat{w} = \Phi^\dagger t$, con $\Phi^\dagger$ la pseudoinversa de Moore–Penrose.[a]

[a] La pseudoinversa generaliza la inversa a matrices no cuadradas o de rango incompleto. Con la SVD $\Phi = USV^\top$ se define $\Phi^\dagger = VS^\dagger U^\top$, invirtiendo solo los valores singulares no nulos; devuelve la solución de menor norma entre todas.

Interpretación geométrica. De (20),

$$\Phi^\top (t - \Phi \hat{w}_{\text{LS}}) = \Phi^\top t - \Phi^\top \Phi \hat{w}_{\text{LS}} = 0. \tag{25}$$

Llamando $r = t - \Phi \hat{w}_{\text{LS}}$, la identidad $\Phi^\top r = 0$ significa $\phi_j^\top r = 0$ para cada columna ϕ_j de Φ: el residuo es ortogonal a todo $\text{col}(\Phi)$. Como $\Phi \hat{w}_{\text{LS}} \in \text{col}(\Phi)$ y $t = \Phi \hat{w}_{\text{LS}} + r$, el ajuste es la *proyección ortogonal* de t sobre el subespacio de las predicciones posibles.

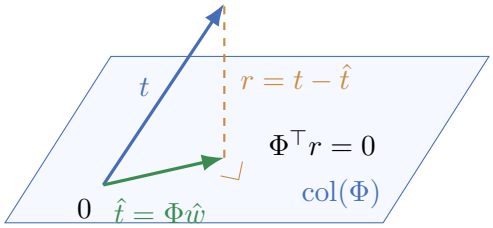


Figura 1: Mínimos cuadrados como proyección ortogonal. t son las respuestas observadas; $\text{col}(\Phi)$ es el conjunto de todas las predicciones posibles Φw; $\Phi \hat{w}$ es el punto de ese subespacio más cercano a t (el ajuste); y $r = t - \Phi \hat{w}$ es el residuo. La marca de ángulo recto y la condición $\Phi^\top r = 0$ dicen que el residuo es perpendicular al subespacio: mínimos cuadrados "tira" t al subespacio en la dirección más corta.

En palabras: mínimos cuadrados "tira" t al plano de las predicciones posibles en la dirección más corta.

1.2. Mínimos cuadrados regularizados

Idea. Penalizar $\|w\|^2$ en la función objetivo. Con ello se evitan pesos enormes que expliquen ruido y se garantiza unicidad aunque Φ no tenga rango completo.

Variables clave. Aparece un parámetro nuevo, $\lambda > 0$, que *no* se estima: se elige. Compite con los valores propios de $\Phi^\top \Phi$, de ahí que su escala dependa de cómo estén escaladas las características. La matriz que ahora se invierte es $A_\lambda = \Phi^\top \Phi + \lambda I_Q$, y no $\Phi^\top \Phi$.

Formulación. Con $\lambda > 0$,

$$\boxed{J_\lambda(w) = \|t - \Phi w\|_2^2 + \lambda \|w\|_2^2.} \tag{26}$$

Dimensiones: $\|t - \Phi w\|^2 \in \mathbb{R}$, $\|w\|^2 = w^\top w \in \mathbb{R}$, $\lambda \in \mathbb{R}_{>0}$, $w \in \mathbb{R}^{Q \times 1}$. El primer término mide el ajuste a los datos y el segundo el "tamaño" de w.

Expansión. Reutilizando (15) y escribiendo la penalización como forma cuadrática, $\lambda\|w\|_2^2 = \lambda\, w^\top w = w^\top(\lambda I_Q)w$:

$$J_\lambda(w) = t^\top t - 2\, w^\top \Phi^\top t + w^\top(\Phi^\top\Phi + \lambda I_Q)w. \tag{27}$$

Dimensiones: $\Phi^\top\Phi + \lambda I_Q \in \mathbb{R}^{Q\times Q}$. Las formas cuadráticas se suman sumando sus matrices.

Gradiente y solución. Sea $A_\lambda = \Phi^\top\Phi + \lambda I_Q$, simétrica por (P1). Los dos primeros términos dan lo mismo que en §1.1 y el tercero, por (P4), da $2A_\lambda w$:

$$\nabla_w J_\lambda(w) = -2\,\Phi^\top t + 2A_\lambda w = 2\Big[(\Phi^\top\Phi + \lambda I_Q)w - \Phi^\top t\Big]. \tag{28}$$

De $\nabla_w J_\lambda = 0$, dividiendo entre 2:

$$\boxed{(\Phi^\top\Phi + \lambda I_Q)w = \Phi^\top t,} \tag{29}$$

y despejando (la matriz es invertible; ver el párrafo siguiente):

$$\boxed{\hat{w}_{\text{RLS}} = (\Phi^\top\Phi + \lambda I_Q)^{-1}\Phi^\top t.} \tag{30}$$

Comprobación: $(\Phi^\top\Phi + \lambda I_Q)\hat{w}_{\text{RLS}} = \Phi^\top t$. ✓

Por qué ahora la solución siempre es única. Para todo $z \in \mathbb{R}^Q$,

$$z^\top(\Phi^\top\Phi + \lambda I_Q)z = z^\top\Phi^\top\Phi z + z^\top(\lambda I_Q)z = \|\Phi z\|_2^2 + \lambda\|z\|_2^2. \tag{31}$$

Si $z \neq 0$ y $\lambda > 0$, entonces $\|\Phi z\|^2 + \lambda\|z\|^2 \geq \lambda\|z\|^2 > 0$: la matriz A_λ es *definida* positiva e invertible aunque Φ no tenga rango completo. En vista espectral, si $\Phi^\top\Phi = U\Lambda U^\top$ con valores propios $\mu_i \geq 0$, entonces $A_\lambda = U(\Lambda + \lambda I)U^\top$ tiene valores propios $\mu_i + \lambda \geq \lambda > 0$, ninguno nulo.

Efecto del parámetro de regularización.

1. **Extremos.** $\lambda \to 0^+$ recupera $\hat{w}_{\text{LS}}$ si $\Phi^\top\Phi$ es invertible; si no, $\hat{w}_{\text{RLS}} \to \Phi^\dagger t$ (mínima norma). Para $\lambda \to \infty$, la identidad exacta $(\Phi^\top\Phi + \lambda I)^{-1} = \frac{1}{\lambda}(I + \frac{1}{\lambda}\Phi^\top\Phi)^{-1}$ muestra que el factor $\frac{1}{\lambda} \to 0$, luego $\hat{w} \to 0$: un prior muy apretado concentra la solución en el origen.

2. **Sesgo y varianza.** Aumentar λ reduce la varianza del estimador (los pesos se vuelven menos sensibles al ruido) y aumenta su sesgo (el estimador deja de ser insesgado). Disminuir λ acerca el modelo a los datos y, con ello, al ruido.

3. **Vista espectral (SVD).** Con $\Phi = USV^\top$ $(N \geq Q)$, $S^\top S = \text{diag}(s_1^2, \ldots, s_Q^2)$ y $\lambda I = V(\lambda I)V^\top$:

$$\hat{w}_{\text{RLS}} = (V(S^\top S + \lambda I)V^\top)^{-1}VS^\top U^\top t = V(S^\top S + \lambda I)^{-1}S^\top U^\top t = \sum_{i=1}^{Q} \frac{s_i}{s_i^2 + \lambda}(u_i^\top t)\, v_i, \tag{32}$$

$$\hat{w}_{\text{LS}} = \sum_{i=1}^{Q} \frac{1}{s_i}(u_i^\top t)\, v_i \qquad \text{(requiere } s_i > 0\text{)}. \tag{33}$$

El factor $\frac{s_i}{s_i^2+\lambda}$ es menor que $\frac{1}{s_i}$ y *atenúa especialmente* las direcciones con s_i pequeño, que son las poco informadas por los datos.

4. **Interpretación como restricción (KKT).** El problema penalizado (26) es el lagrangiano de mín $\|t-\Phi w\|^2$ sujeto a $\|w\|^2 \le c$: las soluciones coinciden cuando $c = \|\hat{w}_{\text{RLS}}\|^2$ (restricción activa) y λ actúa como el multiplicador de Lagrange. Es decir, regularizar equivale a limitar el tamaño de los pesos.

5. **Escala.** Como λ se suma a los valores propios de $\Phi^\top\Phi$, su efecto depende de las unidades de las características; conviene estandarizarlas antes de elegir λ.

Resultado. La regularización garantiza existencia y unicidad para todo $\lambda > 0$ (incluso con rango$(\Phi) < Q$) y encoge los pesos hacia el origen. Más λ significa más sesgo y menos varianza.

1.3. Máxima verosimilitud

Idea. El enfoque estadístico no minimiza un error: elige el w que hace los datos *más probables*. Bajo ruido gaussiano, eso resulta ser el mismo problema que mínimos cuadrados.

Variables clave. La cantidad que se construye es la *verosimilitud* $p(t \mid w)$, una función de w. Depende del ruido $\eta_n \sim \mathcal{N}(0, \sigma_\eta^2)$ y de la independencia de las observaciones. σ_η^2 escala la verosimilitud, pero no el punto donde se maximiza.

Distribución condicional de cada respuesta. Dado w y x_n, el modelo dice $t_n = \phi(x_n)^\top w + \eta_n$ con $\eta_n \sim \mathcal{N}(0, \sigma_\eta^2)$. Sumar una constante a una gaussiana desplaza su media y no cambia su varianza, luego

$$t_n \mid x_n, w \;\sim\; \mathcal{N}(\phi(x_n)^\top w,\; \sigma_\eta^2), \qquad p(t_n \mid x_n, w) = \frac{1}{\sqrt{2\pi\sigma_\eta^2}} \exp\Big(-\frac{(t_n - \phi(x_n)^\top w)^2}{2\sigma_\eta^2}\Big). \tag{34}$$

Verosimilitud conjunta. Los ruidos η_n son independientes por hipótesis; como $t_n = \phi(x_n)^\top w + \eta_n$ con el primer sumando constante dado w, la independencia se transmite a las respuestas. La densidad conjunta es entonces el producto de las marginales:

$$\begin{aligned} p(t \mid w) &= \prod_{n=1}^{N} p(t_n \mid x_n, w) = \prod_{n=1}^{N} \frac{1}{\sqrt{2\pi\sigma_\eta^2}} \exp\Big(-\frac{(t_n - \phi(x_n)^\top w)^2}{2\sigma_\eta^2}\Big) \\ &= (2\pi\sigma_\eta^2)^{-N/2} \exp\Big(-\frac{\|t - \Phi w\|_2^2}{2\sigma_\eta^2}\Big). \end{aligned} \tag{35}$$

Los tres pasos de la simplificación son: (A) las constantes se agrupan, $\prod_n (2\pi\sigma_\eta^2)^{-1/2} = (2\pi\sigma_\eta^2)^{-N/2}$; (B) el producto de exponenciales es la exponencial de la suma, $\prod_n e^{a_n} = e^{\sum_n a_n}$; y (C) la suma de cuadrados es la norma del residuo, $\sum_n (t_n - \phi(x_n)^\top w)^2 = \|t - \Phi w\|^2$, porque $(t - \Phi w)_n = t_n - \phi(x_n)^\top w$.

Log-verosimilitud. El logaritmo convierte el producto en suma y no cambia el arg max (es monótono creciente):

$$\mathcal{L}(w) = \ln p(t \mid w) = -\frac{N}{2}\ln(2\pi\sigma_\eta^2) - \frac{1}{2\sigma_\eta^2}\|t - \Phi w\|_2^2. \tag{36}$$

El primer término no depende de w, y $\frac{1}{2\sigma_\eta^2} > 0$ no afecta el arg max. Por tanto

$$\boxed{\hat{w}_{\mathrm{ML}} = \arg\max_w \mathcal{L}(w) = \arg\min_w \|t - \Phi w\|_2^2.} \tag{37}$$

Estimador de máxima verosimilitud. La condición de optimalidad, por (P6),

$$\nabla_w \|t - \Phi w\|^2 = -2\Phi^\top (t - \Phi w) = 0 \iff \Phi^\top (t - \Phi w) = 0 \iff \Phi^\top \Phi w = \Phi^\top t, \tag{38}$$

son las mismas ecuaciones normales de §1.1. Entonces, si rango$(\Phi) = Q$,

$$\boxed{\hat{w}_{\mathrm{ML}} = (\Phi^\top \Phi)^{-1} \Phi^\top t = \hat{w}_{\mathrm{LS}}.} \tag{39}$$

Detalle que suele confundir. La igualdad es exacta bajo ruido gaussiano i.i.d.: máxima verosimilitud y mínimos cuadrados son el mismo problema con dos nombres. La varianza σ_η^2 solo escala la verosimilitud; no interviene en el arg max. En código, si ambos se obtienen resolviendo el mismo sistema lineal, coinciden a precisión de máquina.

1.4. Máximo a posteriori (MAP)

Idea. Combinar lo que se sabía antes de ver los datos (el prior) con lo que los datos dicen (la verosimilitud de 1.3). El resultado es el mínimo cuadrados regularizado de 1.2.

Variables clave. Aparece una segunda varianza, σ_w^2, que describe la confianza en el prior. Su cociente con la del ruido, σ_η^2/σ_w^2, hace el papel de λ. El prior es isotrópico: la misma varianza en todas las coordenadas, sin preferencia por ninguna.

Prior.

$$w \sim \mathcal{N}(0, \sigma_w^2 I_Q), \qquad \sigma_w^2 > 0, \qquad p(w) = (2\pi\sigma_w^2)^{-Q/2} \exp\Big(-\frac{\|w\|_2^2}{2\sigma_w^2}\Big). \tag{40}$$

La media 0 centra la densidad en el origen, pero lo que realmente penaliza los pesos grandes es la varianza: cuanto menor es σ_w^2, más rápido decae la densidad al alejarse del origen. La matriz $\sigma_w^2 I_Q$ es diagonal, así que cada componente tiene varianza σ_w^2 y, por ser el vector gaussiano, las componentes son independientes ($\|w\|^2 = \sum_k w_k^2$ separa el exponente en producto de densidades marginales). Para σ_w^2 grande la densidad es casi plana y el prior casi no penaliza.

Regla de Bayes.

$$p(w \mid t) = \frac{p(t \mid w)\, p(w)}{p(t)}, \tag{41}$$

donde $p(w \mid t)$ es el *posterior* (lo que sabemos de w tras ver los datos), $p(t \mid w)$ la verosimilitud de 1.3, $p(w)$ el prior y $p(t) = \int p(t \mid w) p(w)\, dw$ la *evidencia*, que no depende de w. Como dividir por una constante positiva no cambia el arg max,

$$\hat{w}_{\mathrm{MAP}} = \arg\max_w p(w \mid t) = \arg\max_w \frac{p(t \mid w) p(w)}{p(t)} = \arg\max_w \big[p(t \mid w) p(w)\big]. \tag{42}$$

Log-posterior. Como en 1.3, se trabaja en escala logarítmica:

$$\ln p(w \mid t) = \ln p(t \mid w) + \ln p(w) - \ln p(t), \tag{43}$$

$$\ln p(w \mid t) = \underbrace{-\frac{N}{2}\ln(2\pi\sigma_\eta^2) - \frac{Q}{2}\ln(2\pi\sigma_w^2) - \ln p(t)}_{\text{constante respecto de } w} - \frac{1}{2\sigma_\eta^2}\|t-\Phi w\|^2 - \frac{1}{2\sigma_w^2}\|w\|^2. \tag{44}$$

Problema de optimización MAP. Maximizar $\ln p(w \mid t)$ equivale a minimizar su opuesto; multiplicando por la constante positiva $2\sigma_\eta^2$ (que no cambia el $\arg\min$) y descartando los términos que no dependen de w:

$$2\sigma_\eta^2\Big[\frac{1}{2\sigma_\eta^2}\|t-\Phi w\|^2 + \frac{1}{2\sigma_w^2}\|w\|^2\Big] = \|t-\Phi w\|^2 + \frac{\sigma_\eta^2}{\sigma_w^2}\|w\|^2, \tag{45}$$

$$\boxed{\hat{w}_{\text{MAP}} = \arg\min_w \Big[\|t-\Phi w\|_2^2 + \frac{\sigma_\eta^2}{\sigma_w^2}\|w\|_2^2\Big].} \tag{46}$$

Relación con la regularización. Comparando con $J_\lambda(w) = \|t-\Phi w\|^2 + \lambda\|w\|^2$ de (26):

$$\boxed{\lambda = \frac{\sigma_\eta^2}{\sigma_w^2} \qquad \Longleftrightarrow \qquad \hat{w}_{\text{MAP}} = \hat{w}_{\text{RLS}}.} \tag{47}$$

Verificación por gradiente. Derivando la forma limpia con (P6) y (P4) (con $A = I_Q$):

$$\nabla_w\|t-\Phi w\|^2 = -2\Phi^\top(t-\Phi w) = -2\Phi^\top t + 2\Phi^\top\Phi w, \tag{48}$$

$$\nabla_w\Big(\frac{\sigma_\eta^2}{\sigma_w^2}\|w\|^2\Big) = \frac{\sigma_\eta^2}{\sigma_w^2}\cdot 2w. \tag{49}$$

Igualando a cero y usando $w = I_Q w$ para factorizar: $(\Phi^\top\Phi + \frac{\sigma_\eta^2}{\sigma_w^2}I_Q)w = \Phi^\top t$, que es (29) con $\lambda = \sigma_\eta^2/\sigma_w^2$.

Cuadro 3: Correspondencia entre el lenguaje bayesiano y el de optimización.

Bayesiano	Optimización
Verosimilitud $t \mid w \sim \mathcal{N}(\Phi w, \sigma_\eta^2 I)$	$\|t-\Phi w\|^2$
Prior $w \sim \mathcal{N}(0, \sigma_w^2 I)$	$\|w\|^2$
$\lambda = \sigma_\eta^2/\sigma_w^2$	coeficiente de penalización
$\hat{w}_{\text{MAP}}$	$\hat{w}_{\text{RLS}}$

Casos límite. Un prior no informativo ($\sigma_w^2 \to \infty$) da $\lambda \to 0$ y recupera $\hat{w}_{\text{LS}}$; un prior muy apretado ($\sigma_w^2 \to 0$) da $\lambda \to \infty$ y concentra la solución en $\hat{w} \to 0$; y datos casi sin ruido ($\sigma_\eta^2 \to 0$) dan $\lambda \to 0$ y devuelven $\hat{w}_{\text{LS}}$. En todos los casos, más ruido o un prior más apretado significan más regularización.

Resultado. La penalización $\lambda\|w\|^2$ de 1.2 es exactamente un prior gaussiano isotrópico. La razón σ_η^2/σ_w^2 compara el ruido de los datos con la confianza en el prior y hace el papel de λ: regularizar y ser bayesiano son la misma cosa vista desde dos lenguajes.

1.5. Implementación y análisis

Idea. Comprobar numéricamente las dos igualdades teóricas ($\hat{w}_{\text{ML}} = \hat{w}_{\text{LS}}$ y $\hat{w}_{\text{MAP}} = \hat{w}_{\text{RLS}}$) y medir el efecto de la regularización.

Variables clave. El experimento usa $N = 300$, $P = 5$, $Q = 20$, ruido $\sigma_\eta = 0{,}5$ y $\lambda = 1$. Para que MAP y RLS resuelvan el mismo problema se fija el prior compatible $\sigma_w^2 = \sigma_\eta^2/\lambda = 0{,}25$. Solo se entrena con el 80 % de los datos; el 20 % restante nunca se usa para ajustar.

Configuración.

Cuadro 4: Parámetros del experimento 1.5.

Símbolo	Valor	Dimensión	Significado
N, P, Q	$300, 5, 20$	—	observaciones, dimensión original, de características
σ_η	0,5	escalar	ruido $\eta_n \sim \mathcal{N}(0, 0{,}5^2)$
λ	1	escalar	regularización
σ_w^2	0,25	escalar	prior compatible σ_η^2/λ
train/test	240/60	—	80 %/20 %
semilla	`20261011`	—	reproducibilidad

Construcción del mapa de características $\Phi(X)$. Las filas $x_n \in \mathbb{R}^5$ se generan i.i.d. con entradas $\mathcal{N}(0, 1)$ y se concatenan tres bloques hasta $Q = 20$:

1. originales: $x_1, \ldots, x_5$ (5 columnas);
2. cuadrados: $x_1^2, \ldots, x_5^2$ (5 columnas);
3. productos por pares $i < j$ en orden lexicográfico (10 columnas):

$$x_1x_2,\ x_1x_3,\ x_1x_4,\ x_1x_5,$$
$$x_2x_3,\ x_2x_4,\ x_2x_5,\ x_3x_4,\ x_3x_5,\ x_4x_5.$$

Así $5 + 5 + 10 = 20 = Q$. Luego $w^* \in \mathbb{R}^{20}$ con entradas $\mathcal{N}(0, 1)$, $\eta \sim \mathcal{N}(0, 0{,}5^2)$ y $t = \Phi w^* + \eta$. La partición se hace por permutación aleatoria de las 300 observaciones.

Estimadores y métricas. Se resuelven dos sistemas lineales, cuyas soluciones son las cuatro fórmulas:

$$\hat{w}_{\text{LS}} = \hat{w}_{\text{ML}} = (\Phi_{\text{tr}}^\top \Phi_{\text{tr}})^{-1} \Phi_{\text{tr}}^\top t_{\text{tr}}, \tag{50}$$
$$\hat{w}_{\text{RLS}} = \hat{w}_{\text{MAP}} = (\Phi_{\text{tr}}^\top \Phi_{\text{tr}} + \lambda I)^{-1} \Phi_{\text{tr}}^\top t_{\text{tr}}, \tag{51}$$

con $\Phi_{\text{tr}} \in \mathbb{R}^{240\times 20}$, $t_{\text{tr}} \in \mathbb{R}^{240}$, $\Phi_{\text{tr}}^\top \Phi_{\text{tr}} \in \mathbb{R}^{20\times 20}$ y $\hat{w} \in \mathbb{R}^{20}$. Se usan tres métricas, cada una con un papel:

$$\text{MSE}_{\text{train}} = \frac{1}{240}\|t_{\text{tr}} - \Phi_{\text{tr}}\hat{w}\|^2 \quad \text{(ajuste)}, \qquad \text{MSE}_{\text{test}} = \frac{1}{60}\|t_{\text{te}} - \Phi_{\text{te}}\hat{w}\|^2 \quad \text{(generalización)}, \tag{52}$$

$$\|\hat{w} - w^*\|^2 = \sum_{k=1}^{20} (\hat{w}_k - w_k^*)^2 \qquad \text{(recuperación del parámetro verdadero)}. \tag{53}$$

Resultados.

Interpretación.

Cuadro 5: Métricas del punto 1.5. Referencia: $\|w^*\|^2 \approx 16{,}685$, $\sigma_\eta^2 = 0{,}25$.

Estimador	MSE train	MSE test	$\|\hat{w} - w^*\|^2$	$\|\hat{w}\|^2$
LS	0,220873	0,300059	0,014807	17,202845
ML	0,220873	0,300059	0,014807	17,202845
RLS	0,221127	0,294384	0,013067	17,081085
MAP	0,221127	0,294384	0,013067	17,081085

- **LS = ML y RLS = MAP:** las diferencias máx $|\hat{w}_{\text{LS}} - \hat{w}_{\text{ML}}|$ y máx $|\hat{w}_{\text{RLS}} - \hat{w}_{\text{MAP}}|$ son 0. Conviene leer ese cero con cuidado: en el código las cuatro fórmulas se obtienen de los dos sistemas anteriores, de modo que las parejas coinciden por construcción. Lo que comprueba el experimento es que el montaje es consistente y, sobre todo, el efecto de la regularización; las identidades ya quedaron demostradas en §1.3 y §1.4.
- **RLS frente a LS:** baja el MSE de prueba (0,3001 → 0,2944) y $\|\hat{w} - w^*\|^2$ (0,0148 → 0,0131), a costa de subir levemente el MSE de entrenamiento (0,2209 → 0,2211). Es el precio del sesgo.
- **Shrinkage:** $\|\hat{w}\|^2$ baja de 17,203 a 17,081: los pesos se acercan algo al origen, como predice la teoría.
- **Condicionamiento:** rango$(\Phi) = 20$, cond$(\Phi^\top\Phi) \approx 15{,}8$, $\lambda_{\text{máx}} \approx 1852$, $\lambda_{\text{mín}} \approx 117$. El problema está bien puesto y, como $\lambda = 1$ es pequeño frente al espectro, el cambio en $\hat{w}$ es suave.

Resultado. La experimentación confirma la teoría y muestra el intercambio sesgo–varianza: con $\lambda = 1$ mejora la generalización (MSE test 0,3001 → 0,2944) y la recuperación de w^* (0,0148 → 0,0131).

Síntesis del Problema 1

Cuadro 6: Los cuatro caminos y sus dos soluciones.

Enfoque	Objetivo	Solución
MC (1.1)	$\|t - \Phi w\|^2$	$(\Phi^\top\Phi)^{-1}\Phi^\top t$ (necesita rango$(\Phi) = Q$)
MC reg. (1.2)	$\|t - \Phi w\|^2 + \lambda\|w\|^2$	$(\Phi^\top\Phi + \lambda I_Q)^{-1}\Phi^\top t$ (única siempre)
ML (1.3)	máx$_w\, p(t \mid w)$	igual a MC (ruido gaussiano)
MAP (1.4)	máx$_w\, p(t \mid w)p(w)$	igual a MC reg. ($\lambda = \sigma_\eta^2/\sigma_w^2$)

Cuatro nombres, dos soluciones: $\hat{w}_{\text{LS}}$ y $\hat{w}_{\text{RLS}}$. La regularización es un prior gaussiano escrito como penalización.

2. Espacios RKHS, embeddings de media y discrepancia entre distribuciones

En el Problema 1 se trabajó con el espacio de características explícito $\phi(x) \in \mathbb{R}^Q$. Aquí ϕ puede tener dimensión infinita y no se materializa: se trabaja con el kernel k, que es su producto interno. El objetivo es doble: representar una distribución entera como un punto de un espacio de Hilbert (2.1–2.2) y medir distancias entre esas representaciones (2.3–2.4).

Herramientas: kernel, RKHS y propiedades usadas (K1)–(K6)

Qué es un kernel y qué es un RKHS. Un kernel $k : \mathcal{X} \times \mathcal{X} \to \mathbb{R}$ es **simétrico** ($k(x, y) = k(y, x)$) y **positivo semidefinido**: para todo conjunto finito de puntos, la matriz de Gram $K_{ij} = k(x_i, x_j)$ es simétrica semidefinida positiva. Todo kernel así induce un único espacio de Hilbert de funciones $\mathcal{H}_k = \{f : \mathcal{X} \to \mathbb{R}\}$ con producto interno $\langle \cdot, \cdot \rangle_{\mathcal{H}_k}$ que *reproduce* el kernel:

$$\boxed{\langle f, k(x, \cdot) \rangle_{\mathcal{H}_k} = f(x) \qquad \forall f \in \mathcal{H}_k,\ \forall x \in \mathcal{X}.} \tag{54}$$

De qué tamaño es $\mathcal{H}_k$ (y por qué importa). La dimensión de un espacio de funciones es cuántas funciones linealmente independientes se necesitan para generar todo el espacio mediante combinaciones lineales. El RKHS *completo* contiene a las funciones $k(z, \cdot)$ y además todas sus combinaciones lineales y sus límites:

$$\mathcal{H}_k = \overline{\text{span}}\{k(z, \cdot) : z \in \mathcal{X}\}, \qquad f(u) = \sum_{i=1}^{m} a_i\, k(z_i, u), \quad a_i \in \mathbb{R}. \tag{55}$$

La dimensión depende del kernel elegido:

- **lineal**, $k(x, u) = x^\top u$: $\mathcal{H}_k \cong \mathbb{R}^P$, luego $d_k = P$ (finita);
- **polinomial** de grado d en $\mathbb{R}^P$: $d_k = \binom{P+d}{d}$ (finita);
- **gaussiano (RBF)**: $d_k = \infty$.

Por eso un elemento de $\mathcal{H}_k$ *no* es una lista finita de coordenadas: con el kernel gaussiano tiene infinitas y no hay manera de listarlas. Esa es la razón de fondo por la que para promediar hace falta una integral y no una suma componente a componente.

Propiedades que se usarán (K1)–(K6).

1. **(K1) Propiedad reproductora.** Con $f = k(y, \cdot)$ y la simetría $k(y, x) = k(x, y)$:

$$\langle k(x, \cdot), k(y, \cdot) \rangle_{\mathcal{H}_k} = k(x, y), \qquad \text{en particular} \qquad \|k(x, \cdot)\|^2_{\mathcal{H}_k} = k(x, x). \tag{56}$$

2. **(K2) Bilinealidad y simetría del producto interno:** $\langle \alpha f + \beta g, h \rangle = \alpha \langle f, h \rangle + \beta \langle g, h \rangle$ y $\langle f, g \rangle = \langle g, f \rangle$.

3. **(K3) Linealidad de la esperanza:** $\mathbb{E}[\alpha f + \beta g] = \alpha \mathbb{E}[f] + \beta \mathbb{E}[g]$.

4. **(K4) Conmutación de $\mathbb{E}$ con el producto interno.** El funcional $g \mapsto \langle f, g \rangle_{\mathcal{H}_k}$ es lineal y acotado, luego conmuta con la integral de Bochner: $\langle f, \mathbb{E}[g] \rangle = \mathbb{E}[\langle f, g \rangle]$.

5. **(K5) Completitud.** $\mathcal{H}_k$ es de Hilbert: toda sucesión de Cauchy converge en él, y la media de Bochner de un elemento integrable permanece en el espacio.

6. **(K6) Kernel característico.** k es característico si el mapa $P \mapsto \mu_P$ es inyectivo: dos distribuciones distintas tienen embeddings distintos. El gaussiano lo es; el lineal no, porque con él $\mu_k = \mathbb{E}[x]$ guarda solo la media y olvida el resto de la distribución.

Detalle que suele confundir. Notación del Problema 2. $k(x, \cdot)$ es una *función* (el kernel con el primer argumento fijo), mientras que $k(x, u)$ es un *número* (ambos argumentos fijos). Igualmente μ_k es una función y $\mu_k(u)$ es un número. Además, $\mathcal{H}_k$ es un *espacio*, no una matriz: lo único matricial que se guarda en el computador es la Gram $K \in \mathbb{R}^{n\times n}$ con $K_{ij} = k(x_i, x_j)$.

2.1. Embedding de media

Idea. Convertir una distribución en un punto del RKHS, promediando las funciones $k(x, \cdot)$ asociadas a cada valor posible de X.

Variables clave. X es una variable aleatoria con distribución P_X y toma valores en $\mathcal{X}$. El objeto que se promedia, $k(X, \cdot)$, es *aleatorio* y vive en $\mathcal{H}_k$, no en $\mathbb{R}$. El resultado μ_k es una *función*: $\mu_k(u)$ es un número y $\mu_k(u) \neq \mu$ en general.

Por qué hace falta una integral. En el Problema 1 el promedio de características $\bar{\phi} = \frac{1}{n}\sum_n \phi(x_n)$ se calculaba coordenada a coordenada porque $\phi(x_n)$ vive en $\mathbb{R}^Q$ y tiene Q números. En un RKHS de dimensión infinita no hay lista de coordenadas que promediar, así que "promediar los puntos $k(x, \cdot)$" debe definirse *sin* mirar coordenadas: mediante una integral.

Definición.

$$\boxed{\mu_k = \mathbb{E}\big[k(X, \cdot)\big] \in \mathcal{H}_k.} \tag{57}$$

La esperanza es la *media de Bochner*. Existe como elemento de $\mathcal{H}_k$ si $\mathbb{E}\|k(X, \cdot)\|_{\mathcal{H}_k} < \infty$, y por (K1) y (K5)

$$\mathbb{E}\|k(X, \cdot)\|_{\mathcal{H}_k} = \mathbb{E}\sqrt{\langle k(X, \cdot), k(X, \cdot)\rangle} = \mathbb{E}\sqrt{k(X, X)} < \infty, \tag{58}$$

condición que el kernel gaussiano cumple sin más, porque $k(X, X) = 1$.

Cómo se evalúa: la integral escalar. Evaluar en un punto fijo u es un funcional lineal y continuo sobre $\mathcal{H}_k$, ya que $|g(u)| = |\langle g, k(u, \cdot)\rangle| \leq \|g\|\sqrt{k(u, u)}$; por tanto conmuta con la integral de Bochner y su valor es un número:

$$\boxed{\mu_k(u) = \big(\mathbb{E}[k(X, \cdot)]\big)(u) = \int_{\mathcal{X}} k(x, u)\, dP_X(x).} \tag{59}$$

Es decir: el valor de μ_k en u es el promedio de la "campana" $x \mapsto k(x, u)$ ponderado por P_X.

Caso discreto: X elige una de las N filas. Si X se toma al azar entre las filas $x_1, \ldots, x_N$ de un conjunto de datos, con probabilidad p_i de elegir la fila i, la integral (59) es una suma ponderada. Para una entrada fija u,

$$\mu_k(u) = \sum_{i=1}^{N} p_i\, k(x_i, u), \tag{60}$$

y en particular, si X toma dos valores a y b con probabilidad $1/2$ cada uno,

$$\mu_k = \tfrac{1}{2}\,k(a,\cdot) + \tfrac{1}{2}\,k(b,\cdot). \tag{61}$$

Aquí u es una observación fija (por ejemplo, una imagen de otro conjunto) y cada $k(x_i, u)$ mide la similitud de la fila elegida con u; el número p_i es la probabilidad de que X tome el valor x_i.

Caso i.i.d. (el que se usa con datos). Si las filas son i.i.d., todas tienen la misma probabilidad $1/N$ y la media se vuelve un promedio simple:

$$\boxed{\hat{\mu}_k(u) = \frac{1}{N}\sum_{i=1}^{N} k(x_i, u).} \tag{62}$$

Este es el objeto que aparece en 2.4 y el análogo exacto de $\bar{\phi} = \frac{1}{n}\sum_i \phi(x_i)$ del Problema 1.

Para cualquier entrada: μ_k es una función. El cálculo anterior devuelve un número por cada u; al variar u sobre todo $\mathcal{X}$ se obtiene una función, un elemento del RKHS que puede evaluarse en cualquier punto:

$$\boxed{\mu_k = \mathbb{E}\big[k(X,\cdot)\big], \qquad \mu_k(u) = \mathbb{E}\big[k(X,u)\big].} \tag{63}$$

Con la muestra, $\hat{\mu}_k = \frac{1}{n}\sum_i k(x_i,\cdot)$. En casos concretos: $\mu_k(u) = 0{,}1$ para $u = u_1$, $\mu_k(u) = 0{,}2$ para $u = u_2$, etc.; la función completa es la que asigna un número a *cada* entrada.

Detalle que suele confundir. El embedding de media *no* es la media aritmética de los datos originales: es la media de las funciones $k(x,\cdot)$, que codifica además potencias y productos de coordenadas. Con kernel lineal sí coincide con lo usual, $\mu_k = \mathbb{E}[x]$, porque entonces "$k(x,\cdot)$" se identifica con el propio vector x. Con un kernel no lineal recoge mucho más que la media.

Cuadro 7: Casos de la integral (59) según cómo se describe P_X.

P_X	$\mu_k(u)$	Interpretación
discreta, masas p_j en a_j	$\sum_j p_j\,k(a_j,u)$	media ponderada de campanas
con densidad $p(x)$	$\int_{\mathbb{R}^P} k(x,u)\,p(x)\,dx$	función suave de u
empírica $\frac{1}{n}\sum_i \delta_{x_i}$	$\frac{1}{n}\sum_{i=1}^{n} k(x_i,u)$	promedio finito (uso con datos)

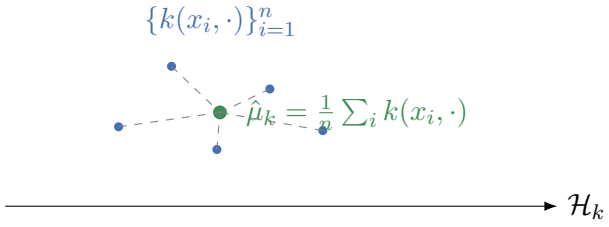


Figura 2: El embedding de media es el centro de masa de los puntos $k(x_i,\cdot) \in \mathcal{H}_k$. Cada observación aporta un punto; la media es su promedio.

2.2. Pertenencia y significado geométrico

Idea. Verificar que μ_k realmente vive en $\mathcal{H}_k$ y que determina a la distribución P_X; sin esto, medir distancias entre embeddings no tendría sentido.

(a) Pertenencia: $\mu_k \in \mathcal{H}_k$. Para cada realización de X, la función $k(X,\cdot)$ es un elemento de $\mathcal{H}_k$ por construcción del RKHS. Bajo $\mathbb{E}\|k(X,\cdot)\| < \infty$, la media de Bochner de $k(X,\cdot)$ existe *dentro* de $\mathcal{H}_k$: un espacio de Hilbert es completo (toda sucesión de Cauchy converge) y la integral de Bochner de un elemento integrable en un espacio de Banach completo es un elemento del mismo espacio. En resumen, μ_k no "escapa" del RKHS.

(b) Es el representante de la distribución. Sea $f \in \mathcal{H}_k$ cualquiera. Por (K4), la propiedad reproductora (54) y (K3):

$$\boxed{\langle f, \mu_k\rangle_{\mathcal{H}_k} = \langle f, \mathbb{E}[k(X,\cdot)]\rangle = \mathbb{E}\big[\langle f, k(X,\cdot)\rangle\big] = \mathbb{E}\big[f(X)\big].} \tag{64}$$

Toda esperanza de una función del RKHS se lee como un producto interno con μ_k: por eso μ_k *es* la representante de la distribución en ese espacio, encapsula P_X en un solo punto.

(c) Cómo se evalúa en un punto. Tomando $f = k(u,\cdot)$ en (54) y $f = \mu_k$ (que ya está en $\mathcal{H}_k$), para cualquier $u \in \mathcal{X}$:

$$\mu_k(u) = \langle \mu_k, k(u,\cdot)\rangle_{\mathcal{H}_k} = \mathbb{E}[k(X,u)], \qquad \hat{\mu}_k(u) = \Big\langle \tfrac{1}{n}\textstyle\sum_i k(x_i,\cdot), k(u,\cdot)\Big\rangle = \tfrac{1}{n}\textstyle\sum_i k(x_i,u). \tag{65}$$

Evaluar el embedding empírico en u es promediar las similitudes kernel entre u y las observaciones, sin construir ϕ ni el RKHS. El mismo número en dos kernels distintos:

- **kernel lineal**, $k(x,u) = x^\top u$: $\hat{\mu}_k(u) = \bar{x}^\top u$ con $\bar{x}$ la media muestral: el embedding mide cuánto se alinea u con la nube de datos (estructura global y lineal).
- **kernel RBF**, $k(x,u) = e^{-\|x-u\|^2/(2\sigma^2)}$: $\hat{\mu}_k(u) = \frac{1}{n}\sum_i e^{-\|x_i-u\|^2/(2\sigma^2)}$, un promedio de similitudes gaussianas que vale cerca de 1 si u está rodeado de datos y cerca de 0 si está lejos (estructura local y no lineal).

(d) Interpretación geométrica. μ_k es el **centro de masa** de la nube $\{k(x,\cdot) : x \in \mathcal{X}\}$: cada valor posible de X aporta un punto del RKHS y μ_k es su promedio ponderado por P_X (figura 2). Cada coordenada del embedding tiene una lectura concreta: al evaluar en u,

$$\mu_k(u) = \mathbb{E}[k(X,u)] \tag{66}$$

es la *similitud media* entre u y la distribución. Así, $\mu_k(u)$ grande significa que u es típico de P_X (hay mucha masa de X cerca de u), y $\mu_k(u)$ pequeño, que u cae lejos de los valores que X toma.

La utilidad de esta representación viene de la inyectividad:

- Si k es **característico** (K6), el mapa $P \mapsto \mu_P$ es inyectivo: dos distribuciones distintas producen embeddings distintos. Por tanto $\mu_X = \mu_Y \iff P_X = P_Y$, y $\|\mu_X - \mu_Y\|_{\mathcal{H}_k}$ es una *distancia entre distribuciones*: se anula si y solo si las distribuciones coinciden.
- Si k **no** es característico, el embedding pierde información. Es el caso del kernel lineal: allí $\mu_k = \mathbb{E}[x]$ guarda solo la media y "olvida" la varianza y la forma de la distribución, de modo que dos distribuciones con la misma media tienen el mismo embedding y el MMD no puede distinguirlas.

La figura 3 ilustra el punto clave: dos distribuciones *distintas* del espacio original producen dos funciones de embedding *distintas*, de modo que sus puntos en el RKHS no coinciden. Con un kernel no característico (por ejemplo el lineal) dos distribuciones con la misma media darían la misma función y el embedding no podría separarlas.

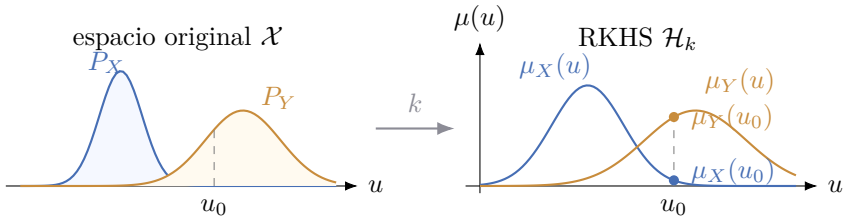


Figura 3: Interpretación geométrica del embedding de media. A la izquierda, dos distribuciones distintas P_X y P_Y sobre el mismo dominio. A la derecha, sus embeddings μ_X y μ_Y vistos como funciones de u. El punto u_0 es *el mismo* en ambos paneles: allí P_X casi no tiene masa mientras P_Y sí, y por eso las similitudes medias $\mu_X(u_0)$ y $\mu_Y(u_0)$ son distintas (obsérvese que $\mu_k(u_0) = \mathbb{E}[k(X, u_0)]$ es una versión suavizada de la densidad, no la densidad misma). Como consecuencia $\mu_X \neq \mu_Y$ y sus puntos en $\mathcal{H}_k$ no coinciden; la distancia entre esos dos puntos es el MMD del punto 2.3.

Geométricamente, representar cada distribución como un punto permite comparar distribuciones con álgebra de vectores: cuanto más lejos están los centros de masa, más distintas son las distribuciones. Esa distancia, $\|\mu_X - \mu_Y\|_{\mathcal{H}_k}$, es el MMD del punto 2.3.

Unicidad del punto que representa a P_X. μ_k es el *único* elemento de $\mathcal{H}_k$ que satisface $\langle f, \mu_k \rangle = \mathbb{E}[f(X)]$ para todo $f \in \mathcal{H}_k$ (ecuación (64)). Si existiera otro ν con la misma propiedad, restando se tendría $\langle f, \mu_k - \nu \rangle = 0$ para todo f; tomando $f = \mu_k - \nu$ resulta $\|\mu_k - \nu\|^2 = 0$, luego $\nu = \mu_k$.

2.3. Discrepancia máxima de medias (MMD): de la definición a la forma matricial

Idea. El MMD es la distancia entre los centros de masa de dos nubes del RKHS. Se traduce a promedios de kernel y luego a matrices de Gram, sin acceder nunca al espacio de características.

Variables clave. Hay dos variables independientes, $X \sim P_X$ e $Y \sim P_Y$, con embeddings μ_X y μ_Y. Se usan dos muestras, $\{x_i\}_{i=1}^n$ y $\{y_j\}_{j=1}^m$, de tamaños n y m que *pueden ser distintos*. Las matrices de Gram asociadas son $K_{XX} \in \mathbb{R}^{n\times n}$, $K_{YY} \in \mathbb{R}^{m\times m}$ y $K_{XY} \in \mathbb{R}^{n\times m}$.

Definición poblacional.

$$\boxed{\mathrm{MMD}^2(P_X, P_Y) = \|\mu_X - \mu_Y\|^2_{\mathcal{H}_k} \geq 0.} \tag{67}$$

Vale 0 exactamente cuando $\mu_X = \mu_Y$ y, si k es característico, eso equivale a $P_X = P_Y$. Por eso funciona como una distancia entre distribuciones.

Paso 1: expandir la norma. Por la definición de norma inducida por el producto interno, la bilinealidad para expandir y la simetría para juntar los términos cruzados (K2):

$$\mathrm{MMD}^2 = \langle \mu_X - \mu_Y, \mu_X - \mu_Y \rangle = \langle \mu_X, \mu_X \rangle - 2\langle \mu_X, \mu_Y \rangle + \langle \mu_Y, \mu_Y \rangle. \tag{68}$$

Paso 2: cada producto interno es un promedio de kernel. Por (K4) se intercambia el producto interno con la esperanza y por (K1) se llega al kernel. Sean $X, X' \overset{\text{i.i.d.}}{\sim} P_X$ (dos copias independientes de la misma distribución), $Y, Y' \overset{\text{i.i.d.}}{\sim} P_Y$, y $X \perp Y$:

$$\langle \mu_X, \mu_X \rangle = \langle \mathbb{E}[k(X,\cdot)], \mathbb{E}[k(X',\cdot)] \rangle = \mathbb{E}\big[\langle k(X,\cdot), k(X',\cdot)\rangle\big] = \mathbb{E}\big[k(X,X')\big], \tag{69}$$

$$\langle \mu_X, \mu_Y \rangle = \langle \mathbb{E}[k(X,\cdot)], \mathbb{E}[k(Y,\cdot)] \rangle = \mathbb{E}\big[k(X,Y)\big], \tag{70}$$

$$\langle \mu_Y, \mu_Y \rangle = \mathbb{E}\big[k(Y,Y')\big]. \tag{71}$$

El primer y el tercer término miden la *autosimilitud* promedio dentro de cada distribución; el cruzado compara directamente P_X con P_Y. La expresión poblacional es

$$\boxed{\mathrm{MMD}^2(P_X, P_Y) = \mathbb{E}[k(X,X')] - 2\,\mathbb{E}[k(X,Y)] + \mathbb{E}[k(Y,Y')].} \tag{72}$$

Paso 3: estimador empírico. Como P_X y P_Y no se conocen, se reemplaza cada esperanza por el promedio sobre todos los pares observados (estimador **sesgado**, estadístico V):

$$\widehat{\mathrm{MMD}}_b^2 = \frac{1}{n^2}\sum_{i=1}^{n}\sum_{i'=1}^{n} k(x_i, x_{i'}) - \frac{2}{nm}\sum_{i=1}^{n}\sum_{j=1}^{m} k(x_i, y_j) + \frac{1}{m^2}\sum_{j=1}^{m}\sum_{j'=1}^{m} k(y_j, y_{j'}). \tag{73}$$

Este estimador es exactamente la distancia al cuadrado entre los embeddings *empíricos* $\hat{\mu}_X = \frac{1}{n}\sum_i k(x_i,\cdot)$ y $\hat{\mu}_Y = \frac{1}{m}\sum_j k(y_j,\cdot)$: $\widehat{\mathrm{MMD}}_b^2 = \|\hat{\mu}_X - \hat{\mu}_Y\|^2_{\mathcal{H}_k} \geq 0$. De ahí su no negatividad y también su sesgo: al incluir los pares $i = i'$ y $j = j'$, cada muestra se compara consigo misma y las nubes empíricas se parecen "demasiado".

Paso 4: forma matricial. Se definen las matrices de Gram y los vectores de unos

$$\begin{aligned} K_{XX} &\in \mathbb{R}^{n\times n}, & (K_{XX})_{ii'} &= k(x_i, x_{i'}), \\ K_{YY} &\in \mathbb{R}^{m\times m}, & (K_{YY})_{jj'} &= k(y_j, y_{j'}), \\ K_{XY} &\in \mathbb{R}^{n\times m}, & (K_{XY})_{ij} &= k(x_i, y_j), \end{aligned} \tag{74}$$

y la identidad que convierte la suma de todas las entradas de una matriz en un triple producto:

$$\mathbf{1}_n^\top A\,\mathbf{1}_n = \sum_{i=1}^{n}\sum_{i'=1}^{n} A_{ii'}, \qquad \text{pues} \qquad (A\mathbf{1}_n)_i = \sum_{i'} A_{ii'} \quad \text{y} \quad \mathbf{1}_n^\top(A\mathbf{1}_n) = \sum_i\sum_{i'} A_{ii'}. \tag{75}$$

Aplicándola a (73):

$$\boxed{\widehat{\mathrm{MMD}}_b^2 = \frac{1}{n^2}\,\mathbf{1}_n^\top K_{XX}\,\mathbf{1}_n + \frac{1}{m^2}\,\mathbf{1}_m^\top K_{YY}\,\mathbf{1}_m - \frac{2}{nm}\,\mathbf{1}_n^\top K_{XY}\,\mathbf{1}_m.} \tag{76}$$

Dimensiones: cada término es un escalar: $\mathbf{1}_n^\top K_{XX}\mathbf{1}_n$ es $(1\times n)(n\times n)(n\times 1)$, $\mathbf{1}_m^\top K_{YY}\mathbf{1}_m$ es $(1\times m)(m\times m)(m\times 1)$ y $\mathbf{1}_n^\top K_{XY}\mathbf{1}_m$ es $(1\times n)(n\times m)(m\times 1)$. El resultado es un número, como debe ser para una distancia.

Sesgado, insesgado y poblacional.

- **Poblacional:** las cantidades exactas de (72).
- **Sesgado (empírico):** incluye los términos diagonales $k(x_i, x_i)$ y $k(y_j, y_j)$. Su esperanza es

$$\mathbb{E}[\widehat{\mathrm{MMD}}_b^2] = \mathrm{MMD}^2 + \frac{1}{n}\big(\mathbb{E}[k(X,X)] - \mathbb{E}[k(X,X')]\big) + \frac{1}{m}\big(\mathbb{E}[k(Y,Y)] - \mathbb{E}[k(Y,Y')]\big), \tag{77}$$

  y con el kernel gaussiano $k(x,x) = 1 > \mathbb{E}[k(X,X')]$, de modo que el sesgo es positivo y de orden $O(1/n + 1/m)$. Siempre es ≥ 0.

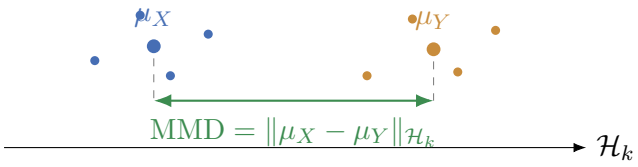


Figura 4: El MMD es la distancia entre dos embeddings de media. Azul: nube de X; naranja: nube de Y; la flecha verde es el MMD.

- **Insesgado:** excluye $i = i'$ y $j = j'$,

$$\widehat{\mathrm{MMD}}_u^2 = \frac{1}{n(n-1)} \sum_{i \neq i'} k(x_i, x_{i'}) + \frac{1}{m(m-1)} \sum_{j \neq j'} k(y_j, y_{j'}) - \frac{2}{nm} \sum_{i,j} k(x_i, y_j), \tag{78}$$

  y puede ser **negativo** por ruido muestral, que es lo correcto bajo H_0 (las dos muestras vienen de la misma distribución).

2.4. Implementación con MNIST y Fashion-MNIST

Idea. Medir en el RKHS de un kernel gaussiano qué tan lejos están dos conjuntos de imágenes, y comparar esa distancia con el "ruido de fondo" de partir un mismo conjunto en dos mitades.

Variables clave. Se comparan vectores de $\mathbb{R}^{784}$ (imágenes 28×28 aplanadas y normalizadas a $[0, 1]$). Todas las Gram son 500×500 porque $n = m = 500$. El hiperparámetro decisivo es el ancho de banda σ del kernel gaussiano, que se fija una sola vez y se usa igual en todas las comparaciones.

Protocolo.

1. 1 000 imágenes de entrenamiento de cada conjunto (semilla `20261011`), cada imagen 28×28 convertida en un vector de $\mathbb{R}^{784}$ y escalada a $[0, 1]$ dividiendo por 255.
2. Cada millar se parte en dos grupos disjuntos de 500: $\mathrm{MNIST}_0, \mathrm{MNIST}_1$ y $\mathrm{Fashion}_0, \mathrm{Fashion}_1$.
3. Comparaciones, todas con $n = m = 500$: (A) MNIST_0 vs $\mathrm{Fashion}_0$ (entre conjuntos); (B) MNIST_0 vs MNIST_1; (C) $\mathrm{Fashion}_0$ vs $\mathrm{Fashion}_1$ (referencias intra-conjunto).
4. Kernel gaussiano $k(u, v) = \exp(-\|u - v\|_2^2/(2\sigma^2))$ con $u, v \in \mathbb{R}^{784}$, y el *mismo* σ en las tres comparaciones.
5. Estimador sesgado (76), **sin** usar etiquetas de clase.

Espacios que intervienen. **Original:** $u \in [0, 1]^{784}$ (los píxeles). **RKHS:** el del kernel gaussiano (no se materializa ϕ). **Matricial:** solo $K_{XX}, K_{YY}, K_{XY} \in \mathbb{R}^{500 \times 500}$. El ancho de banda se fija por la heurística de la mediana de las *distancias* $\|u - v\|$ (no de sus cuadrados) sobre una submuestra de 250 vectores de la muestra combinada: $\sigma \approx 11{,}07$, $\sigma^2 \approx 122{,}5$.

Resultados.

Interpretación.

Cuadro 8: MMD^2 entre MNIST y Fashion-MNIST.

Caso	Comparación	$\widehat{\mathrm{MMD}}_b^2$ (sesgado)	$\widehat{\mathrm{MMD}}_u^2$ (insesgado)
A	entre conjuntos	0,127426	0,125926
B	intra-MNIST	0,001366	−0,000010
C	intra-Fashion	0,000888	−0,000760

- **Separación clara.** El MMD^2 entre conjuntos (0,1274) es entre 90 y 140 veces el piso intra (0,0014 y 0,0009); en unidades de *distancia*, $\|\mu_X - \mu_Y\|$ es unas 10 veces el piso. En el RKHS, MNIST y Fashion-MNIST son nubes distintas.
- **Insesgado negativo en B y C** (-10^{-5} y $-7{,}6 \times 10^{-4}$): es lo correcto bajo H_0, donde $\mathbb{E}[\widehat{\mathrm{MMD}}_u^2] = 0$. El sesgado, en cambio, queda en $\approx 10^{-3}$ a causa de los términos diagonales $k(x_i, x_i) = 1$.
- **Ancho de banda.** Si $\sigma \to \infty$, $k \to 1$ y $\widehat{\mathrm{MMD}}^2 \to 0$; si $\sigma \to 0$, $K \to I_n$ y $\widehat{\mathrm{MMD}}_b^2 \to \frac{1}{n} + \frac{1}{m} =$ 0,004, un valor que ya no depende de los datos y que borra la separación entre A, B y C. De ahí que se use el mismo σ en todas las comparaciones: si cada par eligiera el suyo, los números no serían comparables.
- **Variabilidad muestral.** Las referencias B y C cuantifican la variabilidad propia del muestreo: al partir un mismo conjunto en dos mitades disjuntas, el MMD^2 *no* es exactamente 0 sino del orden de 10^{-3} (sesgado) o incluso negativo (insesgado). Ese es el "ruido de fondo" con el que hay que comparar el valor entre conjuntos; valores del mismo orden no serían evidencia de diferencia.
- **Límite de interpretación.** Un valor de MMD^2 es un tamaño de efecto, no un p-value: para afirmar $P_X \neq P_Y$ haría falta un contraste formal (permutaciones o el test asintótico). Un MMD pequeño no prueba igualdad y uno grande no indica *dónde* está la diferencia.

3. Índice de correlación de Pearson: espacio original y RKHS

Los dos problemas anteriores usaron, sin nombrarla, una misma operación: *centrar*, es decir restar la media. El Problema 1 la usó al expandir formas cuadráticas y el Problema 2 al comparar embeddings. Aquí se estudia esa operación como herramienta propia: primero se escribe el coeficiente de Pearson en forma matricial (3.1); después se extiende el mismo cociente a kernels (3.2), lo que permite comparar dos representaciones de los mismos datos sin construir el espacio de características; y al final se comprueba la coherencia en el caso lineal (3.3) y numéricamente (3.4).

Herramientas: matriz de centrado y trazas (H1)–(H4), (T1)–(T4)

La matriz de centrado es

$$\boxed{H = I_N - \frac{1}{N}\mathbf{1}_N\mathbf{1}_N^\top \in \mathbb{R}^{N\times N},} \tag{79}$$

donde $\mathbf{1}_N \in \mathbb{R}^N$ es el vector de unos. Sus propiedades son las que hacen todo el trabajo:

1. **(H1) Simetría:** $H^\top = H$**.** Por (P1), $H^\top = I_N^\top - \frac{1}{N}(\mathbf{1}_N\mathbf{1}_N^\top)^\top = I_N - \frac{1}{N}\mathbf{1}_N\mathbf{1}_N^\top = H$,

pues $\mathbf{1}_N\mathbf{1}_N^\top$ es simétrico. *Para qué:* permite reordenar productos al calcular numerador y denominador.

2. **(H2) Idempotencia:** $H^2 = H$**.**

$$H^2 = I_N - \frac{2}{N}\mathbf{1}_N\mathbf{1}_N^\top + \frac{1}{N^2}\mathbf{1}_N \underbrace{\mathbf{1}_N^\top\mathbf{1}_N}_{=N}\mathbf{1}_N^\top = I_N - \frac{2}{N}\mathbf{1}_N\mathbf{1}_N^\top + \frac{1}{N}\mathbf{1}_N\mathbf{1}_N^\top = I_N - \frac{1}{N}\mathbf{1}_N\mathbf{1}_N^\top = H. \tag{80}$$

Clave: $\mathbf{1}_N^\top\mathbf{1}_N = N$, luego $\frac{1}{N^2}\cdot N = \frac{1}{N}$ y $-\frac{2}{N} + \frac{1}{N} = -\frac{1}{N}$. *Para qué:* centrar dos veces es centrar una; permite cancelar un H de más.

3. **(H3) Acción: centra el vector.** Para $z \in \mathbb{R}^N$,

$$Hz = z - \frac{1}{N}\mathbf{1}_N(\mathbf{1}_N^\top z) = z - \bar{z}\,\mathbf{1}_N, \qquad \bar{z} = \frac{1}{N}\sum_{n=1}^{N} z_n, \tag{81}$$

y en particular, con $z = \mathbf{1}_N$ (media $\bar{z} = 1$),

$$H\mathbf{1}_N = \mathbf{1}_N - \frac{1}{N}\mathbf{1}_N \cdot N = 0. \tag{82}$$

Multiplicar por H a la izquierda centra las columnas de una matriz; a la derecha, centra las filas.

4. **(H4) Norma al cuadrado.** $z^\top Hz = (Hz)^\top(Hz) = \|Hz\|^2 \geq 0$ por (H1) y (H2).

5. **(T1) Cíclicidad de la traza:** $\operatorname{tr}(AB) = \operatorname{tr}(BA)$ cuando ambos productos están definidos. Permite mover H por dentro del producto sin cambiar el valor.

6. **(T2) Producto interno de Frobenius.** Para $A, B \in \mathbb{R}^{N\times N}$,

$$\langle A, B\rangle_F = \operatorname{tr}(A^\top B) = \sum_{i=1}^{N}\sum_{j=1}^{N} A_{ij}B_{ij}, \tag{83}$$

y si A, B son simétricas, $\operatorname{tr}(A^\top B) = \operatorname{tr}(AB)$.

7. **(T3)** $\operatorname{tr}(ab^\top) = a^\top b$ para $a, b \in \mathbb{R}^N$: la traza de un producto exterior es el producto interno.

8. **(T4) Identidad de rango 1:** $\operatorname{tr}(aa^\top bb^\top) = (a^\top b)^2$. *Demostración:* $aa^\top bb^\top = a(b^\top a)b^\top = (a^\top b)\,ab^\top$, luego $\operatorname{tr}(aa^\top bb^\top) = (a^\top b)\operatorname{tr}(ab^\top) = (a^\top b)(b^\top a) = (a^\top b)^2$, usando (T3) y $b^\top a = a^\top b$.

3.1. Coeficiente de Pearson muestral en forma matricial

Idea. El coeficiente de Pearson es un producto interno entre vectores centrados. Toda la operación de centrado se concentra en la matriz H, y reconocerla es el paso que permite generalizar el coeficiente a kernels.

Variables clave. X, Y son variables escalares (varianzas positivas) y $x, y \in \mathbb{R}^{N\times 1}$ son las N observaciones emparejadas. La media muestral se escribe $\bar{x} = \frac{1}{N}\mathbf{1}_N^\top x$. El resultado $\hat{\rho}_{XY}$ es un escalar en $[-1, 1]$.

Definición y objetivo. Para variables escalares X, Y con varianzas positivas,

$$\rho_{XY} = \frac{\mathbb{E}[(X-\mu_X)(Y-\mu_Y)]}{\sqrt{\mathbb{E}[(X-\mu_X)^2]\,\mathbb{E}[(Y-\mu_Y)^2]}}, \tag{84}$$

y con N observaciones emparejadas la versión muestral reemplaza esperanzas por promedios:

$$\hat{\rho}_{XY} = \frac{\sum_{n=1}^{N}(x_n-\bar{x})(y_n-\bar{y})}{\sqrt{\sum_{n=1}^{N}(x_n-\bar{x})^2}\,\sqrt{\sum_{n=1}^{N}(y_n-\bar{y})^2}}, \qquad \bar{x} = \frac{1}{N}\mathbf{1}_N^\top x, \qquad \bar{y} = \frac{1}{N}\mathbf{1}_N^\top y. \tag{85}$$

Numerador: la covarianza muestral es un producto interno centrado. Por (H3), la n-ésima componente de Hx es $x_n - \bar{x}$. Por tanto

$$\sum_n (x_n-\bar{x})(y_n-\bar{y}) = (Hx)^\top(Hy) = x^\top H^\top H y = x^\top H y, \tag{86}$$

usando (P1) para transponer el producto y (H1)–(H2) para simplificar $H^\top H = H^2 = H$.

Denominador: las varianzas son normas de los mismos vectores.

$$\sum_n (x_n-\bar{x})^2 = (Hx)^\top(Hx) = x^\top H^\top H x = x^\top H x, \qquad \text{análogamente} \qquad \sum_n (y_n-\bar{y})^2 = y^\top H y. \tag{87}$$

Resultado.

$$\boxed{\hat{\rho}_{XY} = \frac{x^\top H y}{\sqrt{(x^\top H x)\,(y^\top H y)}}, \qquad H = I_N - \frac{1}{N}\mathbf{1}_N\mathbf{1}_N^\top.} \tag{88}$$

Cuadro 9: Dimensiones en la fórmula de Pearson.

Objeto	Dimensión	Contenido
x, y	$N \times 1$	observaciones emparejadas
H	$N \times N$	matriz de centrado
$x^\top H y$	escalar	$\sum_n (x_n-\bar{x})(y_n-\bar{y})$
$x^\top H x$	escalar	$\sum_n (x_n-\bar{x})^2$
$y^\top H y$	escalar	$\sum_n (y_n-\bar{y})^2$
$\hat{\rho}_{XY}$	escalar	en $[-1, 1]$

Detalle que suele confundir. Si $x^\top H x > 0$ e $y^\top H y > 0$ el denominador no se anula (por (H4), ambas son normas al cuadrado). La desigualdad de Cauchy–Schwarz garantiza entonces $|\hat{\rho}_{XY}| \le 1$. La fórmula matricial no es "otra cosa": es el mismo Pearson de siempre, escrito de modo que pueda generalizarse.

3.2. Alineamiento centrado en RKHS

Idea. Si en lugar de dos vectores x, y se tienen dos matrices de Gram K_X, K_Y, el análogo de Pearson es el producto interno de Frobenius entre las Gram *centradas*, normalizado.

Variables clave. Aquí $x_n \in \mathbb{R}^P$ e $y_n \in \mathbb{R}^Q$ son las *mismas* N observaciones vistas de dos maneras (dos conjuntos de características emparejadas, o dos kernels distintos sobre los mismos datos). Esto es distinto del Problema 2, donde K_{XX} y K_{YY} venían de dos muestras *distintas*.

Objetos y dimensiones. Sean $x_n \in \mathbb{R}^P$, $y_n \in \mathbb{R}^Q$ para $n = 1, \dots, N$, con kernels simétricos positivos semidefinidos k_X, k_Y y matrices de Gram

$$(K_X)_{nn'} = k_X(x_n, x_{n'}), \qquad (K_Y)_{nn'} = k_Y(y_n, y_{n'}), \qquad K_X, K_Y \in \mathbb{R}^{N\times N}, \tag{89}$$

y por simetría de los kernels, $K_X^\top = K_X$ y $K_Y^\top = K_Y$. Las Gram **centradas** son

$$\boxed{K_{X,c} = HK_XH, \qquad K_{Y,c} = HK_YH.} \tag{90}$$

Dimensiones: $H \in \mathbb{R}^{N\times N}$ y $K_X \in \mathbb{R}^{N\times N}$, luego $K_{X,c} \in \mathbb{R}^{N\times N}$.

Por qué centrar es exactamente HK_XH. Sea $\phi_n = \phi(x_n)$ la imagen de x_n en el espacio de características de k_X y $\bar\phi = \frac{1}{N}\sum_n \phi_n$ su media; las características **centradas** son $\tilde\phi_n = \phi_n - \bar\phi$. La entrada (n, m) de la Gram de esas features centradas es, por (T2) y (K1),

$$\begin{aligned}(K_{X,c})_{nm} &= \langle \tilde\phi_n, \tilde\phi_m\rangle = \langle \phi_n - \bar\phi, \phi_m - \bar\phi\rangle \\ &= k_X(x_n, x_m) - \frac{1}{N}\sum_{n'} k_X(x_n, x_{n'}) - \frac{1}{N}\sum_{m'} k_X(x_{m'}, x_m) + \frac{1}{N^2}\sum_{n',m'} k_X(x_{n'}, x_{m'}).\end{aligned} \tag{91}$$

Por otro lado, expandiendo HK_XH con $H = I_N - \frac{1}{N}\mathbf{1}_N\mathbf{1}_N^\top$ y evaluando la entrada (n, m) término a término:

$$(K_X)_{nm} = k_X(x_n, x_m), \tag{92}$$

$$\Big(\frac{1}{N}K_X\mathbf{1}_N\mathbf{1}_N^\top\Big)_{nm} = \frac{1}{N}\sum_{n'} k_X(x_n, x_{n'}), \tag{93}$$

$$\Big(\frac{1}{N}\mathbf{1}_N\mathbf{1}_N^\top K_X\Big)_{nm} = \frac{1}{N}\sum_{m'} k_X(x_{m'}, x_m), \tag{94}$$

$$\Big(\frac{1}{N^2}\mathbf{1}_N\mathbf{1}_N^\top K_X\mathbf{1}_N\mathbf{1}_N^\top\Big)_{nm} = \frac{1}{N^2}\sum_{n'}\sum_{m'} k_X(x_{n'}, x_{m'}), \tag{95}$$

que es exactamente (91). Luego $K_{X,c} = HK_XH$: H a la izquierda resta la media de cada columna y H a la derecha la de cada fila. Las Gram centradas son simétricas: $(HK_XH)^\top = H^\top K_X^\top H^\top = HK_XH$ por (H1).

Definición del índice. El alineamiento centrado es el producto interno de Frobenius entre las Gram centradas, normalizado:

$$\rho_{\text{RKHS}}(K_X, K_Y) = \frac{\langle K_{X,c}, K_{Y,c}\rangle_F}{\|K_{X,c}\|_F\,\|K_{Y,c}\|_F}. \tag{96}$$

Es el mismo cociente de (88), cambiando los vectores centrados $Hx, Hy \in \mathbb{R}^N$ por matrices centradas y el producto interno usual por el de Frobenius (T2).

Numerador: de productos de Frobenius a trazas. Usando (T2) con $A = K_{X,c}$, $B = K_{Y,c}$ simétricas, la idempotencia (H2) y la cíclicidad (T1):

$$\begin{aligned}\operatorname{tr}(K_{X,c}K_{Y,c}) &= \operatorname{tr}\big((HK_XH)(HK_YH)\big) = \operatorname{tr}\big(HK_X\underbrace{HH}_{=H}K_YH\big) = \operatorname{tr}(HK_XHK_YH)\\ &= \operatorname{tr}\big((K_XHK_YH)H\big) \quad \text{(T1)} = \operatorname{tr}\big(K_XHK_Y\underbrace{HH}_{=H}\big) = \operatorname{tr}(K_XHK_YH). \end{aligned} \tag{97}$$

Denominadores. Es el mismo cálculo con $K_Y = K_X$:

$$\|K_{X,c}\|_F^2 = \operatorname{tr}\big((HK_XH)^2\big) = \operatorname{tr}(HK_XHK_XH) = \operatorname{tr}(K_XHK_XH), \tag{98}$$

$$\|K_{Y,c}\|_F^2 = \operatorname{tr}\big((HK_YH)^2\big) = \operatorname{tr}(K_YHK_YH). \tag{99}$$

Resultado.

$$\boxed{\rho_{\mathrm{RKHS}}(K_X,K_Y) = \frac{\operatorname{tr}(K_XHK_YH)}{\sqrt{\operatorname{tr}(K_XHK_XH)\ \operatorname{tr}(K_YHK_YH)}}.} \tag{100}$$

Detalle que suele confundir. Este índice es *alineamiento centrado de kernels*, no el coeficiente de Pearson clásico de dos variables escalares: vive en la formulación matricial inducida por los RKHS de k_X y k_Y. Se supone que los denominadores son distintos de cero. Sirve para comparar kernels entre sí, por ejemplo al elegir hiperparámetros.

3.3. Caso lineal con datos escalares: verificación de coherencia

Idea. Con kernel lineal y datos escalares el alineamiento debe reducirse al Pearson de §3.1. El resultado $\rho_{\mathrm{RKHS}} = \hat\rho_{XY}^2$ confirma la coherencia entre ambos mundos y explica la pérdida del signo.

Gram de rango 1. Para escalares $x_n, y_n \in \mathbb{R}$ ($P = Q = 1$) y kernels lineales $k_X(u,v) = uv$, $k_Y(s,t) = st$:

$$(K_X)_{nn'} = x_n x_{n'} \implies K_X = xx^\top \in \mathbb{R}^{N\times N}, \qquad K_Y = yy^\top, \tag{101}$$

productos exteriores, es decir matrices de **rango 1**. Con $P, Q > 1$ se tendría $K_X = XX^\top$ de rango $\min(N,P) > 1$ y las trazas no se factorizarían como cuadrados de escalares; de ahí la restricción $P = Q = 1$.

Centrar. Por (H1), $x^\top H = (Hx)^\top$, luego la Gram centrada vuelve a ser un producto exterior, ahora de vectores ya centrados:

$$K_{X,c} = H(xx^\top)H = (Hx)(x^\top H) = (Hx)(Hx)^\top, \qquad K_{Y,c} = (Hy)(Hy)^\top. \tag{102}$$

Trazas. Con la identidad (T4) y $a = Hx$, $b = Hy$, recordando que $\operatorname{tr}(K_XHK_YH) = \operatorname{tr}(K_{X,c}K_{Y,c})$ por §3.2:

$$\operatorname{tr}(K_XHK_YH) = \operatorname{tr}\big((Hx)(Hx)^\top(Hy)(Hy)^\top\big) = \big((Hx)^\top(Hy)\big)^2 = (x^\top Hy)^2, \tag{103}$$

$$\operatorname{tr}(K_XHK_XH) = \operatorname{tr}\big((Hx)(Hx)^\top(Hx)(Hx)^\top\big) = \big((Hx)^\top(Hx)\big)^2 = (x^\top Hx)^2, \tag{104}$$

$$\operatorname{tr}(K_YHK_YH) = \big((Hy)^\top(Hy)\big)^2 = (y^\top Hy)^2, \tag{105}$$

donde en cada caso $(Hx)^\top(Hy) = x^\top H^\top Hy = x^\top Hy$ por (H1)–(H2).

Conclusión. Sustituyendo en (100) y usando (H4), que da $x^\top Hx = \|Hx\|^2 \geq 0$ e $y^\top Hy \geq 0$:

$$\rho_{\text{RKHS}} = \frac{(x^\top Hy)^2}{\sqrt{(x^\top Hx)^2(y^\top Hy)^2}} = \frac{(x^\top Hy)^2}{|x^\top Hx|\,|y^\top Hy|} = \frac{(x^\top Hy)^2}{(x^\top Hx)(y^\top Hy)}$$
$$= \left(\frac{x^\top Hy}{\sqrt{x^\top Hx}\,\sqrt{y^\top Hy}}\right)^2 = \hat{\rho}^2_{XY}. \tag{106}$$

$$\boxed{\rho_{\text{RKHS}}(K_X, K_Y) = \hat{\rho}^2_{XY} \qquad \text{(kernel lineal, } P = Q = 1\text{).}} \tag{107}$$

Por qué se pierde el signo.

- $\hat{\rho}_{XY} \in [-1, 1]$ puede ser negativo, mientras que $\rho_{\text{RKHS}} \geq 0$: para A, B semidefinidas positivas se tiene $\text{tr}(AB) \geq 0$, y junto con Cauchy–Schwarz, $\rho_{\text{RKHS}} \in [0, 1]$.
- **Causa:** $K_X = xx^\top$ es cuadrático en los datos; el producto de Frobenius de dos matrices de rango 1 eleva al cuadrado el producto escalar de los vectores centrados.
- **Invariancia:** $xx^\top = (-x)(-x)^\top$, así que la Gram no cambia si se reemplaza x por $-x$. Por eso ρ_{RKHS} es invariante ante el volteo global de uno de los vectores, mientras que $\hat{\rho}_{XY}$ cambia de signo. En resumen, ρ_{RKHS} mide la *fuerza* de la asociación lineal, no su dirección.

3.4. Verificación numérica

Idea. Comprobar que las formas por sumatorias, la matricial y la de kernels coinciden a precisión de máquina.

Datos. Semilla `20261011`, $N = 40$ observaciones emparejadas con $x_n \sim \mathcal{N}(0, 1)$, en dos casos: *positivo*, $y_n = 1{,}5\,x_n + \mathcal{N}(0, 0{,}4^2)$, y *negativo*, $y_n = -2\,x_n + \mathcal{N}(0, 0{,}3^2)$. La columna "Error" es |valor numérico − valor teórico|; la cota 10^{-15} significa coincidencia hasta el redondeo de coma flotante (no exactamente 0).

Cuadro 10: Comprobación de las identidades del Problema 3.

Comprobación	Valor	Error
Caso positivo ($y = 1{,}5x + \text{ruido}$)		
$\hat{\rho}$ por sumatorias	0,976868	—
$\hat{\rho} = x^\top Hy / \sqrt{(x^\top Hx)(y^\top Hy)}$	0,976868	$\leq 10^{-15}$
ρ_{RKHS} (kernel lineal, $P = Q = 1$)	0,954271	—
$\hat{\rho}^2$	0,954271	$\leq 10^{-15}$
Caso negativo ($y = -2x + \text{ruido}$)		
$\hat{\rho}$	−0,979809	—
ρ_{RKHS} (mismo caso)	0,960026	$\leq 10^{-15}$ vs $\hat{\rho}^2$
$\hat{\rho} < 0$ frente a $\rho_{\text{RKHS}} > 0$	− frente a +	signo perdido
Otras propiedades (caso positivo)		
$\text{tr}(K_{X,c}K_{Y,c})$ vs $\sum_{ij}(K_{X,c})_{ij}(K_{Y,c})_{ij}$	2324,043	0
$H = H^\top$, $H^2 = H$, $H\mathbf{1}_N = 0$	—	$\leq 10^{-15}$

Todo cuadra a precisión de máquina. El caso negativo muestra en vivo la pérdida de signo: $\hat{\rho} = -0{,}9798$ pero $\rho_{\text{RKHS}} = +0{,}9600$.