Taller 1 — Teoría de Aprendizaje de Máquina

Clasificación supervisada, vecinos cercanos y evaluación de modelos

Resolución paso a paso, con cálculos manuales y verificación numérica

Juan David Villota
Universidad Nacional de Colombia
2026-2

Índice

Convenciones, notación y símbolos **2**

1. Clasificación lineal y algoritmo del perceptrón **2**

1.1. Frontera de decisión 2

1.2. Actualización del perceptrón 3

1.3. Ejercicio numérico 5

2. Clasificación por los k vecinos más cercanos **5**

2.1. Cálculo manual 6

2.2. Implementación con `make_moons` 7

2.3. Interpretación 7

3. Evaluación de un clasificador binario **8**

3.1. Matriz de confusión 9

3.2. Métricas 10

3.3. Verificación y análisis 10

Conclusiones **11**

Referencias **12**

Convenciones, notación y símbolos

Tres convenciones valen para todo el documento. (i) Los vectores son columnas, de modo que $w^\top x$ es un escalar. (ii) La primera vez que aparece un objeto se indica su dimensión. (iii) Cada resultado se justifica con la cuenta que lo produce; no se enuncian fórmulas sin trazabilidad.

Cuadro 1: Símbolos usados a lo largo del documento.

Símbolo	Tipo	Qué es
$x \in \mathbb{R}^2$	vector columna	observación de entrada
$y \in \{-1, +1\}$	escalar	etiqueta binaria del perceptrón
$w \in \mathbb{R}^2$, $b \in \mathbb{R}$	vector, escalar	pesos y sesgo del clasificador lineal
$s(x) = w^\top x + b$	escalar	puntuación (función afín)
$\hat{y}$	escalar	clase predicha
$m_i = y_i(w^\top x_i + b)$	escalar	margen de la observación i
$\eta > 0$	escalar	tasa de aprendizaje del perceptrón
q	vector columna	observación nueva en k-NN
$d(q, x_i)$	escalar	distancia euclidiana
k	entero	número de vecinos
TP, TN, FP, FN	enteros	celdas de la matriz de confusión

Notación de índices. En el Problema 1 el subíndice i identifica la observación que se está corrigiendo. En el Problema 2, x_i recorre el conjunto de entrenamiento y q es el punto que se clasifica. En el Problema 3 no hay índices: se cuenta sobre diez pares $(y_j, \hat{y}_j)$, $j = 1, \ldots, 10$.

1. Clasificación lineal y algoritmo del perceptrón

El perceptrón es el clasificador lineal más simple: busca un hiperplano que separe las clases y predice según el lado en que cae cada observación. En $\mathbb{R}^2$ ese hiperplano es una recta. Esta sección resuelve su geometría (1.1), demuestra la identidad central de la regla de aprendizaje (1.2) y ejecuta un paso numérico (1.3).

1.1. Frontera de decisión

La predicción depende solo del signo de la puntuación

$$s(x) = w^\top x + b, \qquad \hat{y} = \begin{cases} +1, & s(x) > 0, \\ -1, & s(x) \leq 0. \end{cases} \tag{1}$$

Con $w = (1, 2)^\top$ y $b = -3$, la frontera $w^\top x + b = 0$ es

$$x_1 + 2x_2 - 3 = 0 \quad \Longleftrightarrow \quad x_2 = \frac{3 - x_1}{2}. \tag{2}$$

Es una recta de pendiente $-1/2$ que corta el eje x_1 en $(3,0)$ y el eje x_2 en $(0,3/2)$. El vector $w = (1,2)$ es normal a la recta y apunta hacia el semiplano donde $s(x) > 0$, es decir, hacia la clase $+1$. La distancia euclidiana de un punto a la recta es $|s(x)|/\|w\|$, con $\|w\| = \sqrt{5}$.

Cuadro 2: Predicción y distancia a la frontera para los cuatro puntos.

Punto	$s(x) = x_1 + 2x_2 - 3$	$\hat{y}$	y	$\lvert s\rvert/\lVert w\rVert$	Justificación
$x_1 = (0,0)$	-3	-1	-1	$3/\sqrt{5} \approx 1.342$	$s \le 0 \Rightarrow -1$
$x_2 = (1,0)$	-2	-1	-1	$2/\sqrt{5} \approx 0.894$	$s \le 0 \Rightarrow -1$
$x_3 = (2,1)$	1	$+1$	$+1$	$1/\sqrt{5} \approx 0.447$	$s > 0 \Rightarrow +1$
$x_4 = (3,1)$	2	$+1$	$+1$	$2/\sqrt{5} \approx 0.894$	$s > 0 \Rightarrow +1$

La Tabla 2 recoge el cálculo punto a punto. Los cuatro puntos quedan estrictamente fuera de la frontera, así que la regla no depende de convenciones en el borde. Los márgenes $m_i = y_i\, s(x_i)$ valen 3, 2, 1 y 2: todos positivos, de modo que la predicción coincide con la etiqueta en los cuatro casos. El punto positivo más cercano a la recta es $x_3 = (2,1)$, a $1/\sqrt{5} \approx 0.447$ unidades; el más alejado es $x_1 = (0,0)$, a $3/\sqrt{5} \approx 1.342$. Esa cercanía importa: un cambio pequeño de w o b puede mover la frontera y cambiar la clase de x_3 antes que la de los demás. La Figura 1 resume la situación.

Detalle que suele confundir. El signo de b no indica el lado de la recta: lo que decide es el signo de $s(x)$. Con $b = -3$ la recta se desplaza, pero el semiplano positivo sigue siendo el que está "a favor" de w. Y la distancia es $|s|/\|w\|$, no $|s|$: dividir por $\|w\|$ es lo que convierte la puntuación en una longitud.

1.2. Actualización del perceptrón

Cuando una observación (x_i, y_i) está mal clasificada se aplica

$$w_{\text{nuevo}} = w + \eta\, y_i x_i, \qquad b_{\text{nuevo}} = b + \eta\, y_i, \qquad \eta > 0. \tag{3}$$

El margen de esa observación es $m_i = y_i\,(w^\top x_i + b)$. Antes de actualizar, $m_i > 0$ significa clasificación correcta, $m_i = 0$ que el punto está en la frontera y $m_i < 0$ clasificación incorrecta.

Qué se quiere demostrar. Que inmediatamente después de la actualización, y para la misma observación,

$$m_{i,\text{nuevo}} = m_i + \eta(\|x_i\|_2^2 + 1). \tag{4}$$

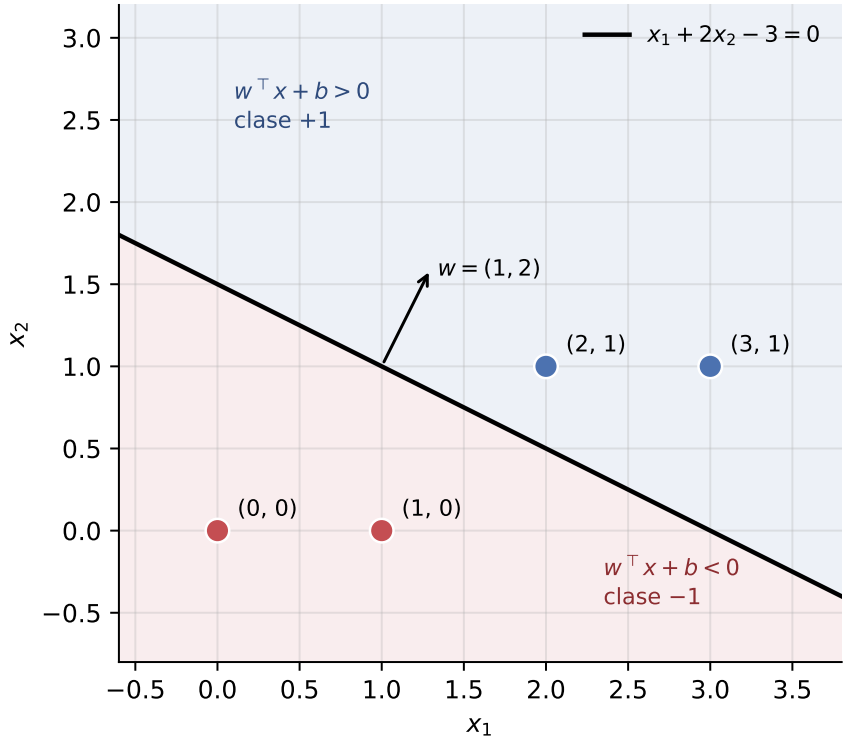


Figura 1: Frontera $x_1 + 2x_2 - 3 = 0$. La zona azul es la región $+1$ y la roja la región -1. La flecha es el vector normal $w = (1, 2)$, que apunta hacia el lado positivo. Los puntos se colorean según su etiqueta verdadera.

Demostración. Se sustituye (3) en la definición del margen y se usa $y_i^2 = 1$:

$$\begin{aligned} m_{i,\text{nuevo}} &= y_i\Big(w_{\text{nuevo}}^\top x_i + b_{\text{nuevo}}\Big) \\ &= y_i\Big((w + \eta y_i x_i)^\top x_i + b + \eta y_i\Big) \\ &= y_i\Big(w^\top x_i + b\Big) + \eta\, y_i^2\, x_i^\top x_i + \eta\, y_i^2 \\ &= m_i + \eta\, \|x_i\|_2^2 + \eta \\ &= m_i + \eta\Big(\|x_i\|_2^2 + 1\Big). \end{aligned} \tag{5}$$

En el tercer paso se distribuyó el producto y se usó que $(y_i x_i)^\top x_i = y_i\, x_i^\top x_i$; en el cuarto, $y_i^2 = 1$ y $x_i^\top x_i = \|x_i\|_2^2$.

Qué implica el resultado.

1. El margen de la observación corregida *siempre aumenta*, en la cantidad estrictamente positiva $\eta(\|x_i\|^2 + 1)$. El aumento no depende de w, de b ni del valor actual del margen.
2. El aumento es proporcional a $\|x_i\|^2$: observaciones con norma grande reciben una corrección mayor. Por eso, si las variables tienen escalas muy distintas, conviene normalizarlas antes de entrenar.
3. Aumentar el margen *no garantiza* que la observación quede bien clasificada en un solo paso. Si $m_i < -\eta(\|x_i\|^2 + 1)$, el nuevo margen sigue siendo negativo. Por ejemplo, con $\eta = 0.1$, $x_i = (1, 0)$ y $m_i = -1$, el nuevo margen es $-1 + 0.1(1 + 1) = -0.8 < 0$.

4. La identidad es local: describe el efecto sobre la observación que disparó la actualización. Otros puntos pueden empeorar su margen con el mismo cambio de w y b. Por eso el perceptrón no minimiza una función objetivo global y su convergencia se estudia aparte (teorema de Novikoff para datos separables).

Detalle que suele confundir. El margen no salta a un valor fijo: aumenta en una cantidad fija. Y el resultado habla del margen de *esa* observación, no del margen mínimo del conjunto ni del número de errores.

1.3. Ejercicio numérico

Con $w = (0, 0)^\top$, $b = 0$, $\eta = 0.5$, $x = (2, 1)^\top$ y $y = +1$, la puntuación inicial es

$$s(x) = w^\top x + b = 0 \cdot 2 + 0 \cdot 1 + 0 = 0. \tag{6}$$

Como la regla (1) asigna $+1$ solo cuando $s(x) > 0$, la predicción es $\hat{y} = -1$, distinta de la etiqueta $y = +1$. La observación está mal clasificada (en la frontera), así que **sí corresponde actualizar**:

$$w_{\text{nuevo}} = (0, 0) + 0.5 \cdot 1 \cdot (2, 1) = (1,\ 0.5), \qquad b_{\text{nuevo}} = 0 + 0.5 \cdot 1 = 0.5. \tag{7}$$

El margen antes de actualizar era $m = y\, s(x) = 0$. Después,

$$m_{\text{nuevo}} = 1 \cdot \Big(1 \cdot 2 + 0.5 \cdot 1 + 0.5\Big) = 3, \tag{8}$$

y la identidad (4) predice

$$m + \eta\Big(\|x\|_2^2 + 1\Big) = 0 + 0.5\,(2^2 + 1^2 + 1) = 0.5 \cdot 6 = 3, \tag{9}$$

que coincide. Además, la nueva puntuación es $s_{\text{nuevo}} = 3 > 0$, así que la observación queda ahora bien clasificada como $+1$. El sesgo pasó de 0 a 0.5: la actualización también desplaza la frontera.

Resultado. $w_{\text{nuevo}} = (1, 0.5)$, $b_{\text{nuevo}} = 0.5$ y el margen pasa de 0 a $3 = 0.5(\|x\|^2 + 1)$. El paso corrige la observación y la deja con margen positivo.

2. Clasificación por los k vecinos más cercanos

k-NN es un método no paramétrico basado en instancias: no estima coeficientes, guarda el conjunto de entrenamiento y decide la clase de una observación nueva por votación mayoritaria entre sus k vecinos más cercanos. La frontera de decisión resulta de unir las regiones de Voronoi de los puntos de entrenamiento, de modo que puede ser arbitrariamente irregular. Su comportamiento depende de dos elecciones: la distancia y el número de vecinos k.

2.1. Cálculo manual

La observación nueva es $q = (1, 1)$ y el conjunto de entrenamiento es el de la Tabla 3. Se usa la distancia euclidiana

$$d(q, x_i) = \sqrt{(q_1 - x_{i,1})^2 + (q_2 - x_{i,2})^2}. \tag{10}$$

Cuadro 3: Conjunto de entrenamiento del enunciado.

Observación	x_1	x_2	x_3	x_4	x_5
x_i	$(0, 0)$	$(1, 0)$	$(3, 1)$	$(0, 3)$	$(1.1, 1.1)$
Clase	A	A	B	B	B

Cuadro 4: Distancias a $q = (1, 1)$, valor exacto, valor decimal y orden.

x_i	Cálculo	$d(q, x_i)$ exacta	Decimal	Orden
$x_1 = (0, 0)$	$\sqrt{1^2 + 1^2}$	$\sqrt{2}$	1.4142	3
$x_2 = (1, 0)$	$\sqrt{0^2 + 1^2}$	1	1.0000	2
$x_3 = (3, 1)$	$\sqrt{2^2 + 0^2}$	2	2.0000	4
$x_4 = (0, 3)$	$\sqrt{1^2 + 2^2}$	$\sqrt{5}$	2.2361	5
$x_5 = (1.1, 1.1)$	$\sqrt{0.1^2 + 0.1^2}$	$\sqrt{0.02} = \frac{\sqrt{2}}{10}$	0.1414	1

El orden de cercanía es

$$x_5 \prec x_2 \prec x_1 \prec x_3 \prec x_4, \tag{11}$$

con distancias 0.1414, 1, 1.4142, 2 y 2.2361. La votación para cada k se resume en la Tabla 5.

Cuadro 5: Vecindad y votación mayoritaria para $k = 1, 3, 5$.

k	Vecinos (en orden)	Clases	Votos A	Votos B	Predicción
1	x_5	B	0	1	B
3	x_5, x_2, x_1	B, A, A	2	1	A
5	x_5, x_2, x_1, x_3, x_4	B, A, A, B, B	2	3	B

Por qué k cambia la predicción. El valor de k fija el radio del vecindario y, con él, qué parte del conjunto participa en el voto. Para $k = 1$ solo cuenta x_5, que es de clase B y está a 0.141 de q: la predicción es local y muy sensible al ruido. Para $k = 3$ entran x_2 y x_1, ambos de clase A, y la mayoría cambia a A. Para $k = 5$ entran x_3 y x_4, de clase B, y la mayoría vuelve a B. No hay empates porque k es impar en los tres casos.

Detalle que suele confundir. La etiqueta de q no es "la del punto más cercano" salvo cuando $k = 1$. Con $k > 1$ manda la composición del vecindario, y esa composición cambia con el radio. Un k par puede producir empate; aquí se evita usando k impar.

2.2. Implementación con `make_moons`

Se generan $N = 300$ observaciones bidimensionales con `make_moons` (`n_samples=300`, `noise=0.20`, `random_state=42`). La partición es 70 % entrenamiento y 30 % prueba, estratificada por clase y con semilla fija. El resultado son 210 observaciones de entrenamiento (105 por clase) y 90 de prueba (45 por clase). La Tabla 6 resume las exactitudes y la Figura 2 muestra los datos.

Cuadro 6: Exactitud de k-NN para tres valores de k.

k	Aciertos train	Exactitud train	Aciertos test	Exactitud test
1	210/210	1.0000	84/90	0.9333
5	201/210	0.9571	86/90	0.9556
15	201/210	0.9571	84/90	0.9333

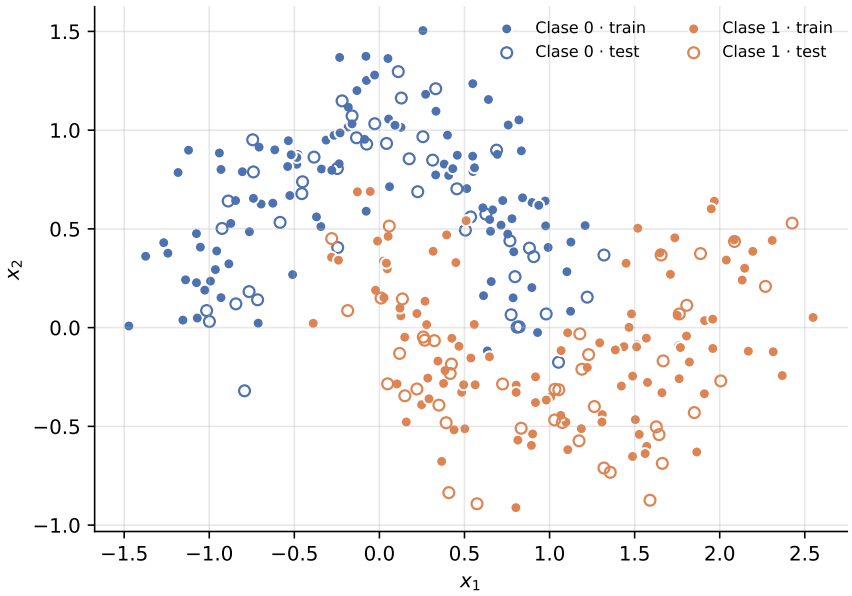


Figura 2: Datos de `make_moons` con `noise=0.20`. Puntos rellenos: entrenamiento; huecos: prueba. El ruido hace que las dos lunas se solapen, así que ninguna frontera las separa perfectamente.

Qué mirar en las figuras. La Figura 3 compara las dos fronteras. En $k = 1$ la frontera rodea puntos individuales y aparecen islas: es la firma de la memorización. En $k = 15$ la frontera corta las lunas con una curva continua, pero ya incluye puntos de la luna contraria cuando el vecindario cruza el solapamiento central.

2.3. Interpretación

k muy pequeño. Con $k = 1$ el vecindario es un solo punto: el modelo reproduce exactamente el conjunto de entrenamiento y alcanza exactitud 1.0000 en train. En prueba cae a 0.9333 (6 errores de 90). La frontera es irregular y muy sensible al ruido; es el régimen de alta varianza y bajo sesgo.

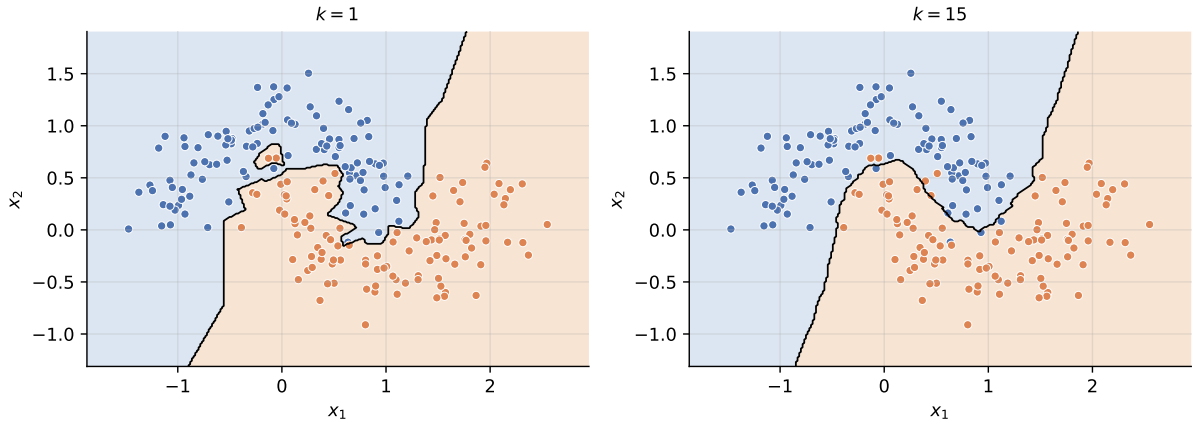


Figura 3: Regiones de decisión con los datos de entrenamiento superpuestos. Izquierda: $k = 1$, frontera quebrada con islas locales. Derecha: $k = 15$, frontera suave que promedia un vecindario amplio.

k muy grande. Con $k = 15$ el vecindario abarca una zona amplia. La frontera se suaviza y la exactitud de train baja a 0.9571, señal de que el modelo ya no memoriza. En prueba obtiene 0.9333: el sesgo aumentó y el vecindario empieza a mezclar puntos de la otra luna. Es el régimen de baja varianza y alto sesgo.

Mejor compromiso en esta partición. $k = 5$ logra 0.9571 en train y 0.9556 en prueba (4 errores de 90), la mejor exactitud de prueba de las tres. El vecindario es suficientemente local para seguir la forma de las lunas y suficientemente amplio para no copiar el ruido.

¿Qué tan sólida es la conclusión? El conjunto de prueba tiene 90 observaciones. Un solo error mueve la exactitud en $1/90 \approx 1.11$ puntos porcentuales, y el error estándar de una exactitud cercana a 0.94 es $\sqrt{0.94 \cdot 0.06/90} \approx 0.025$, es decir, unos 2.5 puntos. La diferencia entre 0.9333 y 0.9556 es de dos observaciones: está dentro del ruido muestral. Se puede afirmar que $k = 5$ fue el mejor *en esta partición*, no que sea el mejor k del problema.

Selección formal de k. Elegir k mirando la exactitud de prueba contamina la evaluación: la prueba deja de ser una estimación independiente y su valor se vuelve optimista. El procedimiento correcto es seleccionar k con validación sobre el entrenamiento (por ejemplo, validación cruzada estratificada de 5 pliegues), quedarse con el k de mejor exactitud media de validación y usar el conjunto de prueba una sola vez, al final, para reportar la generalización. Con $N = 300$ la validación cruzada además aprovecha mejor los datos que una única partición.

3. Evaluación de un clasificador binario

Se tienen diez etiquetas verdaderas y las predicciones del enunciado, con la clase 1 como positiva:

$$y = [0, 0, 0, 0, 1, 1, 1, 1, 1, 1], \qquad \hat{y} = [0, 1, 0, 0, 1, 0, 1, 1, 0, 1]. \tag{12}$$

3.1. Matriz de confusión

La matriz se construye con las clases reales en las filas y las predichas en las columnas, en el orden $(0, 1)$. Cada celda cuenta pares $(y_j, \hat{y}_j)$:

- TP: real 1 y predicho 1 (acierto positivo).
- TN: real 0 y predicho 0 (acierto negativo).
- FP: real 0 y predicho 1 (falsa alarma).
- FN: real 1 y predicho 0 (positivo no detectado).

Al recorrer los diez pares, los únicos desacuerdos son la posición 2 ($y = 0$, $\hat{y} = 1$, un FP) y las posiciones 6 y 9 ($y = 1$, $\hat{y} = 0$, dos FN). Por tanto

$$TP = 4, \qquad TN = 3, \qquad FP = 1, \qquad FN = 2, \tag{13}$$

y la matriz es

$$C = \begin{pmatrix} TN & FP \\ FN & TP \end{pmatrix} = \begin{pmatrix} 3 & 1 \\ 2 & 4 \end{pmatrix}. \tag{14}$$

Las filas suman 4 (clase real 0) y 6 (clase real 1); las columnas suman 5 y 5. El total es $10 = TP + TN + FP + FN$. La Figura 4 representa la matriz.

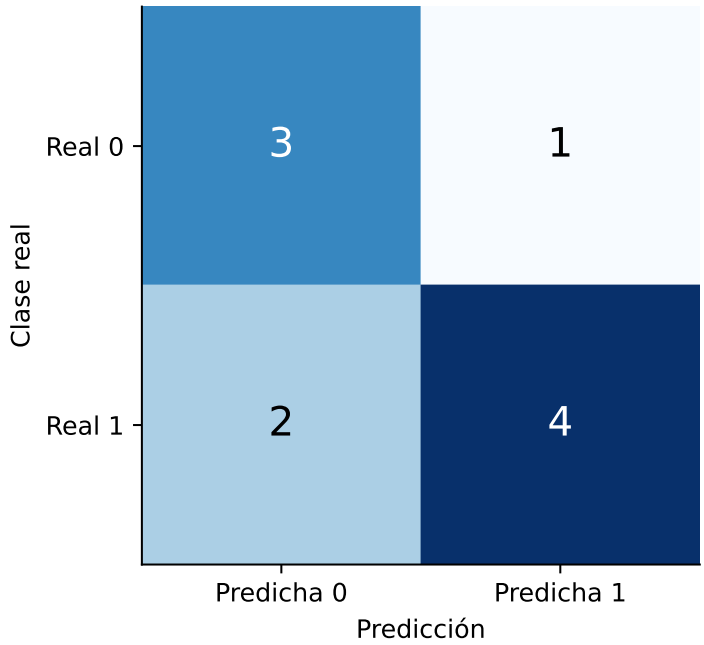


Figura 4: Matriz de confusión del clasificador. La diagonal contiene los aciertos ($3 + 4 = 7$); fuera de ella quedan una falsa alarma y dos positivos no detectados.

3.2. Métricas

Con los conteos anteriores se calculan las cuatro medidas:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} = \frac{4+3}{10} = \frac{7}{10} = 0.7000, \tag{15}$$

$$\text{Precision} = \frac{TP}{TP + FP} = \frac{4}{4+1} = \frac{4}{5} = 0.8000, \tag{16}$$

$$\text{Recall} = \frac{TP}{TP + FN} = \frac{4}{4+2} = \frac{4}{6} = \frac{2}{3} \approx 0.6667, \tag{17}$$

$$F_1 = \frac{2\,\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} = \frac{2 \cdot \frac{4}{5} \cdot \frac{2}{3}}{\frac{4}{5} + \frac{2}{3}} = \frac{16/15}{22/15} = \frac{8}{11} \approx 0.7273. \tag{18}$$

Qué evalúa cada medida.

- **Exactitud:** proporción total de aciertos. Es simétrica entre clases y trata igual un FP y un FN.
- **Precisión:** de las observaciones que el modelo marca como positivas, qué fracción lo es realmente. Mide la confiabilidad de la alarma positiva.
- **Recall:** de los positivos reales, qué fracción se detecta. Mide la cobertura; su complemento $1 - \text{Recall} = FN/(TP + FN) = 1/3$ es la tasa de positivos perdidos.
- F_1**:** media armónica de precisión y recall. Penaliza los desbalances entre ambas; es alta solo si las dos son altas.

Lectura del caso. El clasificador es más preciso que sensible: cuando dice 1 acierta el 80 % de las veces, pero deja pasar 1/3 de los positivos reales. Reportar solo 0.70 de exactitud oculta esa asimetría.

3.3. Verificación y análisis

La Tabla 7 compara el cálculo manual con las funciones de scikit-learn. Los cuatro valores coinciden hasta el cuarto decimal.

Cuadro 7: Verificación de las métricas con scikit-learn.

Métrica	Cálculo manual	`sklearn`	Coincide
Accuracy	$7/10 = 0.7000$	0.7000	Sí
Precision	$4/5 = 0.8000$	0.8000	Sí
Recall	$4/6 = 0.6667$	0.6667	Sí
F_1	$8/11 = 0.7273$	0.7273	Sí

Dos situaciones en las que la exactitud sola engaña.

1. **Clases desbalanceadas.** Supóngase un conjunto con 95 casos negativos y 5 positivos. Un clasificador que siempre predice 0 acierta $95/100 = 0.95$, pero su recall es 0: no

detecta ningún positivo y su precisión es indefinida (0/0). La exactitud se ve excelente porque la clase mayoritaria domina el promedio; las métricas por clase y la matriz de confusión revelan el fracaso. Algo análogo ocurre aquí: la clase mayoritaria es 1 (6/10), así que el clasificador trivial que siempre predice 1 obtendría 0.60; el modelo evaluado solo la supera en 0.10.

2. **Costos asimétricos.** En tamizaje médico, detección de fraude o control de calidad, un FN (enfermo no detectado, fraude no bloqueado, pieza defectuosa aprobada) suele costar mucho más que un FP (examen adicional, revisión manual, pieza buena rechazada). La exactitud asigna el mismo peso a ambos errores y no refleja el costo real. En esos casos se reportan precisión, recall y F_1, y se ajusta el umbral de decisión según la matriz de costos.

Buena práctica. Reportar siempre la matriz de confusión junto con exactitud, precisión, recall y F_1, indicar el balance de clases y comparar la exactitud con la del clasificador trivial. Un solo número nunca resume el desempeño de un clasificador binario.

Conclusiones

1. La frontera $w^\top x + b = 0$ divide el plano en dos semiplanos y el signo de $s(x)$ asigna la clase. Con $w = (1, 2)^\top$ y $b = -3$, los puntos $(0, 0)$ y $(1, 0)$ caen en la clase -1, y $(2, 1)$ y $(3, 1)$ en la clase $+1$.

2. Tras una actualización del perceptrón, el margen de la observación corregida aumenta exactamente en $\eta(\|x_i\|^2 + 1)$. El aumento es fijo y positivo, pero no garantiza corregir la observación en un solo paso.

3. En el ejercicio numérico, $s = 0$ obliga a actualizar: $w = (1, 0.5)$, $b = 0.5$ y el margen pasa de 0 a 3.

4. En k-NN, k controla el radio efectivo del vecindario. Para $q = (1, 1)$, $k = 1$ predice B, $k = 3$ predice A y $k = 5$ predice B.

5. Con `make_moons`, $k = 1$ memoriza (train 1.0000, test 0.9333), $k = 15$ suaviza (test 0.9333) y $k = 5$ logra el mejor equilibrio (test 0.9556). La diferencia es de dos observaciones sobre 90, así que la elección formal de k debe hacerse por validación, no con la prueba.

6. La matriz de confusión es $[[3, 1], [2, 4]]$, con $TP = 4$, $TN = 3$, $FP = 1$ y $FN = 2$. Las métricas son accuracy 0.7000, precision 0.8000, recall 0.6667 y $F_1 = 0.7273$. La exactitud sola no basta: el desbalance de clases y los costos asimétricos pueden volverla engañosa.

Referencias

1. T. Hastie, R. Tibshirani y J. Friedman, *The Elements of Statistical Learning*, 2.ª ed. Springer, 2009, capítulos 2 y 4.
2. F. Pedregosa *et al.*, "Scikit-learn: Machine Learning in Python", *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
3. L. Novikoff, "On convergence proofs for perceptrons", en *Proceedings of the Symposium on the Mathematical Theory of Automata*, vol. 12, 1963, pp. 615–622.